Proyecto 2. Resultados

Reto 18: Hackeando el cuerpo humano
HuBMAP + HPA: segmentación de unidades funcionales de tejido

Iris Ayala (23965) Jonatan Díaz (23837) Anggie Quezada (23643)

Universidad del Valle de Guatemala
Facultad de Ingeniería, Departamento de Ciencias de la Computación
CC3084 Data Science, Semestre II, 2026

12 de octubre de 2026

Resumen

Este informe presenta la solución del grupo al reto *HuBMAP - Hacking the Human Body*, que consiste en segmentar unidades funcionales de tejido (FTU) en imágenes histológicas de cinco órganos humanos. Se analizaron las 351 imágenes etiquetadas del conjunto de entrenamiento, se construyó un pipeline de preprocesamiento reutilizable y se entrenaron tres arquitecturas seleccionadas a partir de la revisión bibliográfica: U-Net con encoder ResNet34, U-Net++ con encoder ResNet34 y SegFormer con encoder MIT-B0. Sobre un conjunto de prueba reservado de 53 imágenes, SegFormer obtuvo el mejor desempeño (Dice de 0.629 e IoU de 0.510), fue el mejor en los cinco órganos y además es el modelo más ligero, por lo que se seleccionó como referencia de la aplicación. El pulmón fue el órgano más difícil para los tres modelos; su baja cobertura de FTU es contexto exploratorio, no una causa demostrada. Se entrega la aplicación y los resultados históricos, pero la inferencia de imágenes nuevas permanece bloqueada porque los pesos entrenados no están disponibles localmente.

Índice

1. Introducción **3**

1.1. Situación problemática 3

1.2. Problema científico 3

1.3. Contenido del informe 3

2. Objetivos **4**

3. Marco teórico **4**

3.1. Procesamiento de imágenes histológicas 4

3.2. Contexto médico: tejido y unidades funcionales 5

3.3. Aprendizaje profundo para segmentación 5

3.4. Hallazgos de las soluciones ganadoras del reto 6

4. Metodología **7**

4.1. Pasos seguidos . . . 7

4.2. Conjuntos de entrenamiento, validación y prueba . . . 7

4.3. Selección de los algoritmos . . . 8

4.4. Herramientas . . . 8

4.5. Recursos de cómputo . . . 9

5. Resultados y análisis de resultados **9**

5.1. Características del conjunto de datos original . . . 9

5.2. Limpieza y preprocesamiento . . . 10

5.3. Análisis exploratorio . . . 11

5.3.1. Variables y observaciones disponibles . . . 11

5.3.2. Resumen de las variables numéricas . . . 11

5.3.3. Tablas de frecuencia de las variables categóricas . . . 12

5.3.4. Cruce de variables . . . 12

5.3.5. Correlaciones . . . 13

5.3.6. Outliers y valores faltantes . . . 13

5.3.7. Variable derivada: área de la FTU . . . 13

5.3.8. Gráficos exploratorios . . . 14

5.3.9. Exploración visual de las imágenes . . . 17

5.3.10. Resumen de hallazgos e implicaciones para el modelado . . . 17

5.4. Entrenamiento y ajuste de parámetros . . . 17

5.5. Comparación de los algoritmos . . . 19

5.5.1. Desempeño por órgano . . . 20

5.5.2. Selección del modelo . . . 23

5.5.3. Limitaciones . . . 23

5.6. Aplicación . . . 24

6. Conclusiones **28**

Repositorio **31**

1. Introducción

HuBMAP (*Human BioMolecular Atlas Program*) es un programa que busca mapear el cuerpo humano a nivel de célula, es decir, construir un mapa detallado de cómo están organizados los tejidos sanos en cada órgano (HuBMAP Consortium, 2019). La competencia de Kaggle nace de ese programa y combina datos de HuBMAP con los del Atlas de Proteínas Humanas (HPA). Lo que pide es encontrar y delimitar, dentro de fotografías de tejido, las llamadas unidades funcionales de tejido o FTU (Jain, Godwin, Joshi et al., 2023).

La formulación original de de Bono et al. (2013) vincula las FTU con la organización alrededor de capilares. Para este reto se adopta la definición funcional: una organización mínima de tejido que realiza una función fisiológica específica y se repite dentro del órgano (Jain, Godwin, Joshi et al., 2023). La organización capilar no se impone como condición universal. El reto incluye cinco órganos: riñón, próstata, bazo, pulmón e intestino grueso. En cada uno la FTU se ve distinta porque cada órgano tiene su propia estructura: en riñón corresponde a los glomérulos, en intestino grueso a las criptas, en próstata a las unidades glandulares (Bidanta et al., 2025).

1.1. Situación problemática

Actualmente, identificar las unidades funcionales de tejido en una imagen de biopsia lo hacen patólogos a mano, revisando la muestra al microscopio y marcando dónde están esas estructuras. El procedimiento toma tiempo, depende de la experiencia de la persona que lo realiza y no es escalable a miles de imágenes de distintos órganos.

A eso se suma un problema de consistencia: como las muestras pueden venir de laboratorios distintos con procesos de preparación distintos, dos imágenes del mismo órgano no siempre se ven igual. Esto complica todavía más hacer el trabajo de forma manual y reproducible, e introduce variabilidad entre observadores que es difícil de cuantificar.

1.2. Problema científico

El problema se formula como una tarea de segmentación semántica: a partir de una imagen de tejido, ¿se puede entrenar un modelo que marque con precisión en qué zonas de la imagen se encuentran las unidades funcionales de tejido, sin importar de qué órgano se trate ni de qué fuente provenga la muestra?

La dificultad adicional es que el conjunto de datos solo contiene unos cuantos órganos y fuentes, de manera que el modelo debe aprender un patrón que generalice en lugar de memorizar la apariencia particular de cada órgano.

1.3. Contenido del informe

La sección 2 plantea los objetivos. La sección 3 resume la teoría sobre procesamiento de imágenes histológicas, el contexto médico de las FTU y los algoritmos de aprendizaje profundo para segmentación. La sección 4 describe los pasos seguidos, la división de los datos, la selección de algoritmos y las herramientas. La sección 5 presenta los datos, su preprocesamiento, el análisis exploratorio, el entrenamiento, la comparación de los modelos y la aplicación. La sección 6 cierra con las conclusiones.

2. Objetivos

Objetivo general. Desarrollar y comparar modelos de aprendizaje profundo que segmenten las unidades funcionales de tejido en imágenes histológicas de cinco órganos humanos, y ponerlos a disposición en una aplicación interactiva.

Objetivos específicos.

1. Explorar y describir los datos de la competencia para entender la composición de las imágenes, las variables que las acompañan y el desbalance de la variable objetivo.
2. Construir un pipeline de preprocesamiento reutilizable que prepare las imágenes y sus máscaras tanto para el entrenamiento como para la aplicación.
3. Seleccionar, a partir de la revisión bibliográfica, y entrenar al menos tres arquitecturas de segmentación con un protocolo común.
4. Evaluar los modelos en un conjunto de prueba reservado con métricas adecuadas para segmentación (Dice e IoU), por órgano y por tiempo de inferencia, y seleccionar el mejor.
5. Desarrollar una aplicación que permita explorar los datos, segmentar imágenes nuevas con los modelos entrenados y comparar su rendimiento.

3. Marco teórico

3.1. Procesamiento de imágenes histológicas

Una imagen digital a color se representa como un arreglo de tres canales (rojo, verde y azul) en el que cada píxel guarda la intensidad de cada canal. En patología digital, las láminas de tejido se escanean a alta resolución y producen imágenes de miles de píxeles por lado; en este reto, la mayoría mide 3000×3000 píxeles. Cada píxel representa una distancia física fija sobre el tejido, el *tamaño de píxel*, que en las imágenes de HPA es de $0.4\,\mu\text{m}$.

Segmentación semántica. A diferencia de la clasificación, que asigna una etiqueta a toda la imagen, la segmentación semántica asigna una etiqueta a cada píxel. En este problema la etiqueta es binaria: el píxel pertenece a una FTU o al fondo. El resultado es una *máscara* del mismo tamaño que la imagen. En el conjunto de datos las máscaras vienen comprimidas en *run-length encoding* (RLE), que guarda pares (posición inicial, longitud) de tramos consecutivos de píxeles marcados.

Redimensionamiento. Las redes neuronales no pueden procesar imágenes de 3000×3000 en la memoria de una GPU de consumo, por lo que se reducen a un tamaño fijo. Las imágenes se reducen con interpolación por área, que promedia los píxeles y evita patrones de *aliasing*, y las máscaras con vecino más cercano, para que sigan siendo binarias. Cuando las imágenes provienen de fuentes con distinto tamaño de píxel, se reescalan primero a un tamaño de píxel común para que una misma estructura tenga el mismo tamaño aparente (Jain, Godwin, Joshi et al., 2023).

Variabilidad de tinción. El color de una imagen histológica depende de la tinción, del laboratorio y del escáner. Hay dos estrategias para que un modelo sea robusto a esa variabilidad: la *normalización de tinción*, que lleva cada imagen a una tinción de referencia (Macenko et al., 2009), y el *aumento de datos de color*, que altera al azar el tono, la saturación, el brillo y el contraste durante el

entrenamiento. Tellez et al. (2019) estudian los efectos del aumento de datos y de la normalización de tinción en patología computacional; no se presupone que una estrategia sea universalmente superior.

Aumento de datos geométrico. El tejido no tiene una orientación fija, de modo que voltear o rotar una imagen produce un ejemplo igual de válido. Estas transformaciones multiplican la variedad del conjunto de entrenamiento y son especialmente útiles cuando hay pocas imágenes (Ronneberger et al., 2015).

3.2. Contexto médico: tejido y unidades funcionales

Las imágenes HPA del reto son de inmunohistoquímica: los anticuerpos se visualizan con DAB (3,3'-diaminobencidina) y contratinción con hematoxilina. La porción HuBMAP incorpora PAS (*Periodic Acid-Schiff*) y hematoxilina-eosina (H&E) (Jain, Godwin, Joshi et al., 2023). No corresponde describir todas las muestras como PAS ni identificar la tinción solo por el color.

El patrón que un algoritmo debe reconocer no es una lesión ni una enfermedad, sino una estructura anatómica normal que realiza una función fisiológica específica (Jain, Godwin, Joshi et al., 2023). Bidanta et al. (2025) catalogaron 22 tipos de FTU en 10 órganos, incluyendo relaciones anidadas, y muestran que su tamaño y composición cambian mucho de un órgano a otro. En los cinco órganos del reto, la FTU corresponde al glomérulo en riñón, a la cripta en intestino grueso, a la unidad glandular en próstata, a la pulpa blanca en bazo y al alvéolo en pulmón. La dificultad está en que esa organización cambia de forma, tamaño y contraste según el órgano, y en que la apariencia del tejido depende también de cómo se preparó y escaneó la muestra.

Como los datos provienen de dos fuentes distintas, y cada una prepara y escanea las muestras a su manera, un mismo órgano puede verse diferente según de dónde salió la imagen. Este punto es central: la meta es que el modelo reconozca las FTU sin importar el órgano ni la fuente, y no que memorice los casos que vio durante el entrenamiento. Una competencia anterior de HuBMAP, limitada a glomérulos de riñón, mostró que un modelo de este tipo puede integrarse a un atlas de referencia para segmentar tejido a escala (Jain, Godwin, Ju et al., 2023).

3.3. Aprendizaje profundo para segmentación

Redes convolucionales. Las redes neuronales convolucionales (CNN) aprenden filtros que detectan bordes, texturas y formas cada vez más complejas a medida que se profundiza en la red. Litjens et al. (2017) revisaron más de 300 trabajos y encontraron que las CNN dominan la clasificación, detección y segmentación en imagen médica. ResNet (He et al., 2016) introdujo conexiones residuales que permiten entrenar redes profundas, y sus versiones preentrenadas en ImageNet se usan como *encoder* (extractor de características) en muchas arquitecturas de segmentación. Partir de pesos preentrenados (*transfer learning*) reduce la cantidad de datos necesaria para entrenar.

U-Net. Ronneberger et al. (2015) propusieron una arquitectura encoder-decoder: el encoder reduce la imagen y extrae características, y el decoder la vuelve a ampliar hasta producir una máscara del tamaño de la entrada. Las *conexiones de salto* pasan los detalles finos del encoder al decoder, lo que permite delimitar bordes con precisión. U-Net funciona bien con pocas imágenes gracias al aumento de datos y se convirtió en la referencia de la segmentación biomédica (Siddique et al., 2021). El pipeline completo y autoconfigurable nnU-Net mostró resultados competitivos en 23 conjuntos de datos (Isensee et al., 2021); ese resultado no se atribuye a la U-Net simple entrenada en este proyecto.

U-Net++. Zhou et al. (2020) rediseñaron las conexiones de salto de U-Net como una red de conexiones densas y anidadas que combinan características de varias escalas antes de llegar al decoder. La idea es reducir la diferencia semántica entre el encoder y el decoder, lo que resulta útil cuando el tamaño de los objetos a segmentar varía mucho, como ocurre con las FTU de distintos órganos.

Transformers y SegFormer. Los *vision transformers* dividen la imagen en parches y usan mecanismos de atención para relacionar regiones lejanas entre sí, algo que las convoluciones capturan con dificultad. SegFormer (Xie et al., 2021) combina un encoder transformer jerárquico (Mix Transformer, MIT), que produce características a varias escalas sin codificación posicional, con un decoder ligero formado solo por capas MLP. Su variante más pequeña, MIT-B0, tiene alrededor de 3.7 millones de parámetros. Otras alternativas consideradas fueron DeepLabV3+ (Chen et al., 2018) y CoaT (Xu et al., 2021).

Función de pérdida. Cuando la FTU ocupa una pequeña parte de la imagen, la entropía cruzada binaria (BCE) por sí sola favorece predecir fondo. La pérdida Dice (Milletari et al., 2016) mide directamente el solapamiento entre predicción y máscara y es menos sensible al desbalance. Es común combinarlas: la BCE aporta gradientes estables por píxel y la pérdida Dice optimiza la métrica de interés.

Métricas. Sea P el conjunto de píxeles predichos como FTU y G el de la máscara real:

$$\text{Dice} = \frac{2\,|P \cap G|}{|P| + |G|}, \qquad \text{IoU} = \frac{|P \cap G|}{|P \cup G|}.$$

Ambas valen 1 cuando la predicción coincide exactamente con la máscara y 0 cuando no se solapan. El coeficiente de Dice es la métrica oficial del reto (Jain, Godwin, Joshi et al., 2023). La exactitud por píxel no es adecuada: como se verá en el análisis exploratorio, un modelo que predijera fondo en toda la imagen tendría más del 94 % de exactitud.

Optimización. AdamW (Loshchilov & Hutter, 2019) es una variante del optimizador Adam que aplica la regularización por *weight decay* de forma desacoplada del gradiente. La *detención temprana* (early stopping) interrumpe el entrenamiento cuando la métrica de validación deja de mejorar durante un número fijo de épocas (la *paciencia*) y conserva el mejor modelo visto, con el objetivo de limitar el sobreajuste, sin garantizar su ausencia.

3.4. Hallazgos de las soluciones ganadoras del reto

Según Jain, Godwin, Joshi et al. (2023), los tres primeros lugares obtuvieron un Dice promedio de 0.835, 0.833 y 0.832 en el conjunto de prueba privado. Riñón e intestino grueso fueron los órganos más fáciles y pulmón el más difícil (Dice de 0.72 a 0.74), por la variación en la forma de los alvéolos. Las estrategias más efectivas fueron los ensambles con al menos un vision transformer, los datos externos con pseudo-etiquetado y el aumento de datos fuerte o la normalización de tinción. SegFormer fue el mejor transformer: como modelo individual (MIT-B4) llegó a un Dice de 0.828, casi igual que el ensamble completo. El tercer lugar ajustó el tamaño de píxel entre las imágenes de HPA y HuBMAP.

4. Metodología

4.1. Pasos seguidos

1. **Investigación.** Revisión bibliográfica de algoritmos de segmentación en imagen médica y de las soluciones ganadoras del reto.
2. **Análisis exploratorio.** Descripción de las variables de `train.csv`, cruces entre variables y construcción de una variable derivada con la proporción de FTU de cada imagen.
3. **Preprocesamiento.** Decodificación de las máscaras, ajuste del tamaño de píxel, redimensionamiento, aumento de datos y división de los datos, todo en un módulo reutilizable (`src/preprocess.py`).
4. **Selección de modelos.** Tres arquitecturas: una CNN de referencia, una CNN mejorada y un transformer.
5. **Entrenamiento.** Un loop común para los tres modelos, con la misma partición, función de pérdida y criterio de selección.
6. **Evaluación.** Dice, IoU y tiempo de inferencia sobre el conjunto de prueba, por imagen, por órgano y por modelo, y selección del mejor modelo.
7. **Aplicación.** Interfaz interactiva que reutiliza el preprocesamiento y los modelos entrenados.

4.2. Conjuntos de entrenamiento, validación y prueba

Se trabajó únicamente con las 351 imágenes de `train.csv`, porque las etiquetas del conjunto de prueba de la competencia están ocultas. Se dividieron en 70 % para entrenamiento (245 imágenes), 15 % para validación (53) y 15 % para prueba (53), **estratificando por órgano** con una semilla fija (42). El conjunto es pequeño y desbalanceado (99 imágenes de riñón contra 48 de pulmón): sin estratificar, un órgano podría quedar casi sin imágenes en validación o prueba y las métricas por órgano no serían confiables.

Cuadro 1: Imágenes por órgano en cada conjunto

Órgano	Entrenamiento	Validación	Prueba
kidney	69	15	15
prostate	65	14	14
largeintestine	40	9	9
spleen	37	8	8
lung	34	7	7
Total	245	53	53

El conjunto de entrenamiento se usa para ajustar los pesos; el de validación, para elegir la mejor época de cada modelo (detención temprana); y el de prueba, solo una vez al final, para comparar los modelos con una partición reservada. Esto no demuestra independencia por donante: la estratificación se hizo por imagen y órgano, no por paciente. La división se guardó en `data/splits.csv` para que todo el equipo usara exactamente las mismas imágenes.

4.3. Selección de los algoritmos

Cuadro 2: Modelos seleccionados

Modelo	Tipo	Justificación
U-Net / ResNet34	CNN (referencia)	Arquitectura de referencia en segmentación biomédica (Ronneberger et al., 2015; Siddique et al., 2021); sigue siendo muy competitiva (Isensee et al., 2021).
U-Net++ / ResNet34	CNN mejorada	Conexiones de salto multiescala, útiles porque el tamaño de las FTU varía mucho entre órganos (Zhou et al., 2020).
SegFormer / MIT-B0	Transformer	Familia con resultados favorables en el reto; el resultado individual de 0.828 corresponde a MIT-B4, no a MIT-B0 (Jain, Godwin, Joshi et al., 2023; Xie et al., 2021). MIT-B0 se elige por su menor costo de cómputo.

U-Net y U-Net++ comparten el mismo encoder (ResNet34 preentrenado en ImageNet), de modo que la comparación contrasta sus decoders bajo el protocolo común, sin aislar causalmente todos los factores de entrenamiento. Para SegFormer se eligió la variante más pequeña, MIT-B0, por la memoria disponible. Como alternativas se consideraron DeepLabV3+ (Chen et al., 2018) y CoaT (Xu et al., 2021).

4.4. Herramientas

Se eligió Python porque concentra las bibliotecas de aprendizaje profundo y de visión por computadora que usan las soluciones del reto. El código se versionó en GitHub y se trabajó sobre un cuaderno compartido en el que cada integrante desarrolló su sección.

Cuadro 3: Entorno local actual verificado para la entrega, no reconstrucción del entorno histórico

Herramienta	Versión	Uso
Python	3.11.17	Intérprete local administrado por uv.
PyTorch	2.14.1	Inferencia CPU; el lock conserva la variante CUDA Windows.
segmentation-models-pytorch	0.5.0	U-Net y U-Net++ con encoder ResNet34.
Transformers	5.17.0	SegFormer con encoder MIT-B0.
Albumentations	2.0.8	Aumento de datos geométrico y de color.
OpenCV (headless)	5.0.0.93	Redimensionamiento de imágenes.
tifffile	2026.3.3	Lectura de imágenes TIFF.
pandas / NumPy	3.0.5 / 2.4.6	Datos tabulares y máscaras.
Matplotlib / seaborn	3.11.1 / 0.13.2	Visualizaciones estáticas.
Streamlit / Plotly	1.65.0 / 7.1.0	Aplicación y gráficas interactivas.
uv	0.12.23	Entorno y dependencias reproducibles (`uv.lock`).

4.5. Recursos de cómputo

Las versiones de la tabla corresponden a los paquetes instalados para esta entrega local. Los CSV históricos no conservan un inventario completo de versiones; el lock actual no demuestra qué versiones se usaron en la ejecución original.

El entrenamiento se ejecutó en una laptop con GPU NVIDIA GeForce RTX 4060 Laptop (8 GB de VRAM), procesador AMD Ryzen 9 8945HS y 16 GB de RAM, sobre Windows 11. La configuración de entrenamiento se diseñó para caber también en una RTX 4050 Laptop de 6 GB, la GPU más limitada del equipo. Antes de entrenar se ejecutó una prueba de memoria (*preflight*) de cada modelo con un paso completo de entrenamiento; los picos medidos fueron 475 MiB para U-Net, 505 MiB para U-Net++ y 186 MiB para SegFormer. Estos valores describen el entorno histórico reportado, no una medición nueva en este Mac. Los CSV conservados no registran la duración total del entrenamiento ni tiempos CPU; no se estima esa duración a partir del forward GPU. La aplicación está implementada para CPU, pero su latencia con pesos reales no se verificó en esta entrega.

5. Resultados y análisis de resultados

5.1. Características del conjunto de datos original

Se trabajó con el archivo `train.csv`, que es el único que trae etiquetas completas, ya que no se participó en la competencia como tal, y con las 351 imágenes `.tiff` de `train_images/` (5.8 GB). El archivo tiene 351 filas y 10 columnas. Cada fila corresponde a una imagen de tejido con su información asociada.

Cuadro 4: Variables disponibles en `train.csv`

Variable	Tipo	Descripción
`id`	Identificador	Código de la imagen. Sin valor analítico propio.
`organ`	Categórica	Órgano de la muestra (5 niveles).
`data_source`	Categórica	Fuente de la muestra (HuBMAP o HPA).
`img_height`	Numérica	Alto de la imagen en píxeles.
`img_width`	Numérica	Ancho de la imagen en píxeles.
`pixel_size`	Numérica	Micrómetros representados por cada píxel.
`tissue_thickness`	Numérica	Grosor del corte de tejido.
`rle`	Texto	Máscara de la FTU codificada en run-length encoding.
`age`	Numérica	Edad del donante en años.
`sex`	Categórica	Sexo del donante.

La columna `rle` merece una aclaración porque no es una variable convencional. El formato *run-length encoding* no almacena la máscara píxel por píxel, sino pares de números (posición inicial, longitud) que indican tramos consecutivos de píxeles marcados. Guardar una máscara de 3000×3000 como matriz sería inviable dentro de una celda de texto; el rle la comprime a unos cuantos miles de caracteres.

5.2. Limpieza y preprocesamiento

Limpieza. No se encontraron valores nulos ni filas duplicadas en `train.csv`, de modo que no fue necesario eliminar ni imputar ninguna observación. Se convirtieron `organ`, `data_source` y `sex` a tipo categórico, ya que pandas las cargaba como texto plano y el tipo categórico las identifica correctamente como conjuntos cerrados de valores.

Todo el preprocesamiento de imágenes está en el módulo `src/preprocess.py`, de modo que el entrenamiento y la evaluación comparten el pipeline. Para cargas nuevas, `src/inference.py` reproduce la conversión RGB, el redimensionamiento y la transformación de validación:

1. **Decodificación de máscaras.** En esta competencia los píxeles del RLE se numeran por columnas (de arriba hacia abajo y luego de izquierda a derecha). Si se reconstruye por filas, la máscara queda transpuesta. Para verificar la decodificación, cada una de las 351 máscaras se decodificó y se volvió a codificar, y el resultado fue idéntico al RLE original.
2. **Ajuste del tamaño de píxel.** Cada imagen se reescala a 0.4 µm por píxel antes de redimensionarla. En `train.csv` todas las imágenes ya tienen ese valor, pero las cargas nuevas no declaran un espaciado verificado: la aplicación asume explícitamente 0.4 µm/píxel y no ofrece ajuste físico por el usuario. Otra escala puede alterar el resultado.
3. **Redimensionamiento a** 384×384 **píxeles**, con interpolación por área para las imágenes y vecino más cercano para las máscaras. La proporción de FTU de cada máscara se puede variar al redimensionar, especialmente en estructuras pequeñas.
4. **Caché.** Leer un `.tiff` de 3000×3000 en cada época es muy lento, así que cada imagen y su máscara se guardan una sola vez como `.png` a 384 px (702 archivos, 89 MB). A partir de ahí el entrenamiento, la evaluación y la aplicación leen de esa caché. Las cargas nuevas no necesitan la caché del conjunto de datos.
5. **Aumento de datos**, solo en entrenamiento (tabla 5).
6. **Normalización** con la media y la desviación estándar de ImageNet, porque los encoders de los tres modelos vienen preentrenados en ImageNet.

Cuadro 5: Aumento de datos aplicado en entrenamiento

Tipo	Transformación	Motivo
Geométrica	Volteos horizontal y vertical, rotaciones de 90°, rotación de ±30° y escala de 0.8 a 1.2	El tejido no tiene una orientación fija y las FTU varían de tamaño.
Color	Tono, saturación y valor (HSV); brillo y contraste; gamma	Simula diferencias de tinción entre laboratorios (Tellez et al., 2019).
Desenfoque	Gaussiano leve	Simula imágenes escaneadas con menos nitidez.

Se optó por aumento de color en lugar de una normalización dedicada a una tinción de referencia (Macenko et al., 2009), como estrategia para introducir variación durante el entrenamiento. Tellez

et al. (2019) aportan contexto sobre ambas estrategias. Sin una comparación local ni muestras HuBMAP etiquetadas en esta partición, no se demuestra cuál generaliza mejor entre fuentes.

5.3. Análisis exploratorio

5.3.1. Variables y observaciones disponibles

El conjunto tiene 351 observaciones, una por imagen de tejido, y 10 variables. Tres son categóricas (`organ`, `data_source`, `sex`), cinco son numéricas (`img_height`, `img_width`, `pixel_size`, `tissue_thickness`, `age`), una es un identificador (`id`) y una es texto estructurado (`rle`). No hay valores faltantes en ninguna de las 351 filas.

5.3.2. Resumen de las variables numéricas

Cuadro 6: Estadísticos descriptivos de las variables numéricas

	media	desv. est.	mín	Q1	mediana	máx
`img_height`	2978.4	91.0	2308	3000	3000	3070
`img_width`	2978.4	91.0	2308	3000	3000	3070
`pixel_size`	0.4	0.0	0.4	0.4	0.4	0.4
`tissue_thickness`	4.0	0.0	4	4	4	4
`age`	60.4	16.0	21	55	60	84

Casi todas las imágenes miden 3000×3000 píxeles: la mediana y el percentil 75 de `img_height` e `img_width` caen exactamente en 3000, y el mínimo de 2308 indica que existen algunas imágenes más pequeñas, aunque la variación es baja frente al tamaño típico (desviación estándar de aproximadamente 91 píxeles). Además, en las 351 filas el alto y el ancho coinciden siempre, es decir que todas las imágenes son cuadradas.

`pixel_size` y `tissue_thickness` no varían en absoluto: valen 0.4 y 4 en las 351 filas, con desviación estándar cero. En este archivo no aportan ninguna información para diferenciar observaciones. La explicación aparece en la tabla de frecuencias de la sección siguiente: `train.csv` solo contiene imágenes de origen HPA, que se escanean siempre con esos mismos parámetros. En el conjunto de HuBMAP estos valores sí varían.

En cuanto a `age` hay dispersión considerable: el promedio es de 60 años, con donantes entre 21 y 84 años y una desviación estándar de 16 años, lo que indica que el conjunto cubre un rango amplio de edades adultas.

5.3.3. Tablas de frecuencia de las variables categóricas

Cuadro 7: Distribución de las variables categóricas

Variable	Nivel	Frecuencia	Proporción
`organ`	kidney	99	28.2 %
	prostate	93	26.5 %
	largeintestine	58	16.5 %
	spleen	53	15.1 %
	lung	48	13.7 %
`data_source`	HPA	351	100.0 %
	HuBMAP	0	0.0 %
`sex`	Male	229	65.2 %
	Female	122	34.8 %

En `organ`, riñón (99) y próstata (93) son los órganos con más observaciones, seguidos de intestino grueso (58), bazo (53) y pulmón (48, el menos representado). No es un desbalance extremo, pero conviene tenerlo en cuenta al comparar métricas entre órganos.

En `data_source`, el 100 % de las filas provienen de HPA: no hay ninguna observación de HuBMAP en `train.csv`. Este es un hallazgo importante. Aunque la competencia combina ambas fuentes, el archivo con el que se trabaja solo contiene la parte pública de HPA, mientras que las muestras de HuBMAP quedan en el conjunto de prueba oculto. En consecuencia, este análisis describe solo esa porción de los datos y no el problema completo.

En `sex`, el 65.2 % de los donantes son hombres (229) y el 34.8 % mujeres (122). Este desbalance se explica en parte por `prostate`, que por razones biológicas solo tiene donantes hombres, como se revisa en el cruce de variables.

5.3.4. Cruce de variables

Cuadro 8: Tabla de contingencia entre órgano y sexo

Órgano	Female	Male	% Male
kidney	37	62	62.6 %
prostate	0	93	100.0 %
largeintestine	32	26	44.8 %
spleen	28	25	47.2 %
lung	25	23	47.9 %

El cruce de `organ` con `sex` explica buena parte del desbalance de sexo: `prostate` es 100 % masculino (93 de 93), lo cual es un patrón esperado por la biología del órgano y no un error de datos. `kidney` también se inclina hacia hombres (63 %), mientras que intestino grueso, pulmón y bazo están bastante más parejos (45 a 55 %). Como próstata es el segundo órgano más frecuente, entre ese y riñón explican casi todo el desbalance general observado.

El cruce de `organ` con `age` muestra que `largeintestine` es un caso claramente distinto: su edad mediana es de 83 años, muy por encima de los otros cuatro órganos, que rondan entre 53 y 60 años de mediana. Esto indica que `organ` y `age` no son independientes en este conjunto. No parece un error, sino el resultado de cómo se repartieron los donantes por tipo de muestra, pero es importante tenerlo presente: cualquier patrón que se observe en `age` puede en realidad estar reflejando de qué órgano proviene la imagen.

5.3.5. Correlaciones

La matriz de correlación no muestra relaciones lineales relevantes entre las variables numéricas originales. La correlación entre `age` e `img_height` o `img_width` es prácticamente nula (0.04), y con `id` también (0.02, esperable porque `id` es solo un identificador sin significado real). `img_height` e `img_width` correlacionan perfectamente entre sí (1.0), lo cual tiene sentido porque todas las imágenes son cuadradas.

`pixel_size` y `tissue_thickness` aparecen como `NaN` en toda la matriz. Esto no es un error de cálculo: al ser constantes, su desviación estándar es cero y el coeficiente de Pearson queda indefinido porque implica una división entre cero. Dentro de las variables numéricas originales no hay pares que valga la pena modelar juntos por una relación lineal; lo interesante del conjunto está en las categóricas y en sus cruces.

5.3.6. Outliers y valores faltantes

En `age`, el método del rango intercuartílico marca 13 outliers (límites de 28 a 100 años), todos con valor 21 años, el mínimo del conjunto. Sin embargo, como se vio en el cruce con `organ`, la edad depende bastante del órgano: 21 años cae dentro del rango normal de pulmón y bazo, así que estos outliers globales no son errores ni casos raros, sino donantes jóvenes que resultan atípicos solo si se ignora a qué órgano pertenecen. No se eliminó ni transformó ninguna observación; se documenta el hallazgo.

En `img_height` el resultado es distinto. Como el 75 % de las imágenes miden exactamente 3000 px, el rango intercuartílico es cero y el método marca como outlier cualquier imagen que no mida 3000 (25 de 351, concentradas en riñón y próstata). Aquí el método clásico no resulta útil porque la variable no es continua en la práctica, sino casi binaria: 3000 o no 3000. La explicación más probable es que esas imágenes sean recortes de tejido que no alcanzaron el tamaño estándar de escaneo, no errores de carga, de modo que tampoco se descartan.

5.3.7. Variable derivada: área de la FTU

Las variables tabulares originales dicen poco sobre el problema real. La información que de verdad importa está dentro de la columna `rle`, porque es la que describe lo que el modelo debe predecir. Por eso se construyó una variable derivada.

Aprovechando que el formato rle almacena pares (inicio, longitud), basta con sumar las longitudes para obtener la cantidad de píxeles marcados, sin necesidad de reconstruir la máscara completa. A partir de ahí se define:

$$\texttt{mask_frac} = \frac{\text{píxeles marcados como FTU}}{\texttt{img_height} \times \texttt{img_width}}$$

es decir, la proporción de la imagen ocupada por la unidad funcional de tejido.

Cuadro 9: Proporción de la imagen ocupada por la FTU, por órgano

Órgano	n	media	mediana	mín	máx
largeintestine	58	0.193	0.196	0.021	0.348
prostate	93	0.154	0.138	0.010	0.429
spleen	53	0.101	0.086	0.008	0.343
kidney	99	0.030	0.028	0.003	0.080
lung	48	0.021	0.013	0.001	0.089
global	351	0.099	0.059	0.001	0.429

5.3.8. Gráficos exploratorios

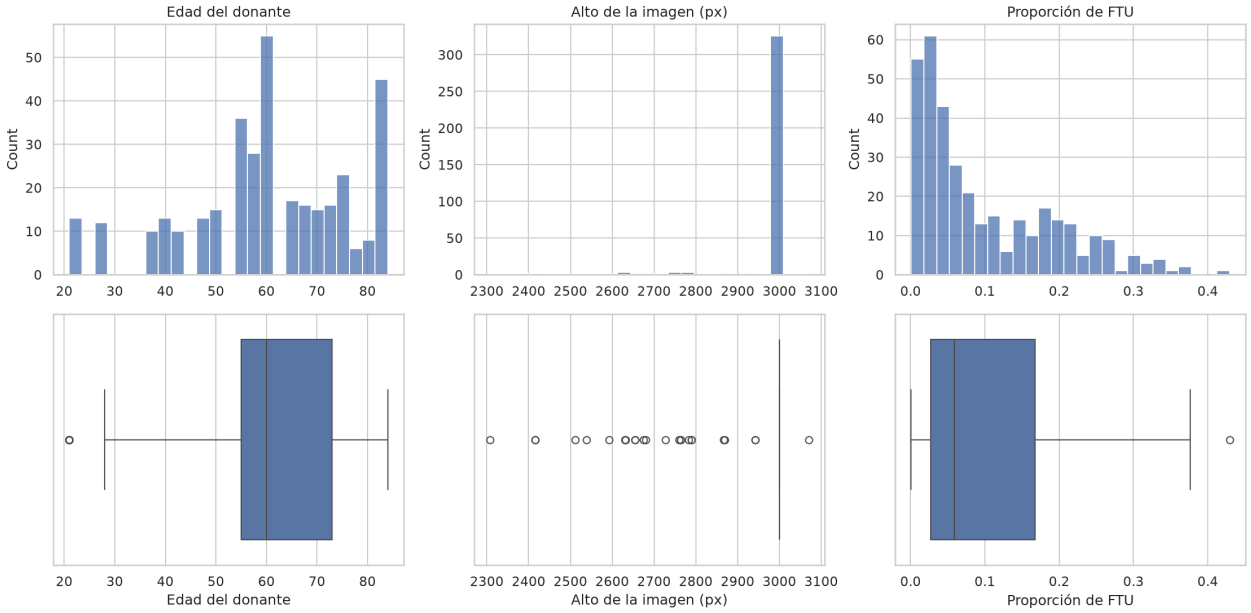


Figura 1: Histogramas y diagramas de caja de edad, alto de imagen y proporción de FTU.

En `age` la distribución va de 21 a 84 años, se concentra entre los 55 y los 73 y tiene una mediana de 60 años. Es una población de donantes mayoritariamente adulta mayor, y la cola hacia los donantes jóvenes es bastante más delgada, de modo que el conjunto no representa por igual todas las edades.

En `img_height` el gráfico se ve casi como una sola barra: 326 de las 351 imágenes son de 3000×3000 píxeles y el resto son algo más pequeñas. El diagrama de caja marca todas esas imágenes menores como outliers, pero como ya se explicó no son errores.

En `mask_frac` la distribución está claramente sesgada a la derecha: la mediana es 0.059, alrededor del 6 % de la imagen, pero existen casos que llegan a 0.43. Esto significa que en la mayoría de las

imágenes la estructura a segmentar ocupa una parte pequeña de la fotografía, lo cual implica un problema con clases fuertemente desbalanceadas a nivel de píxel.

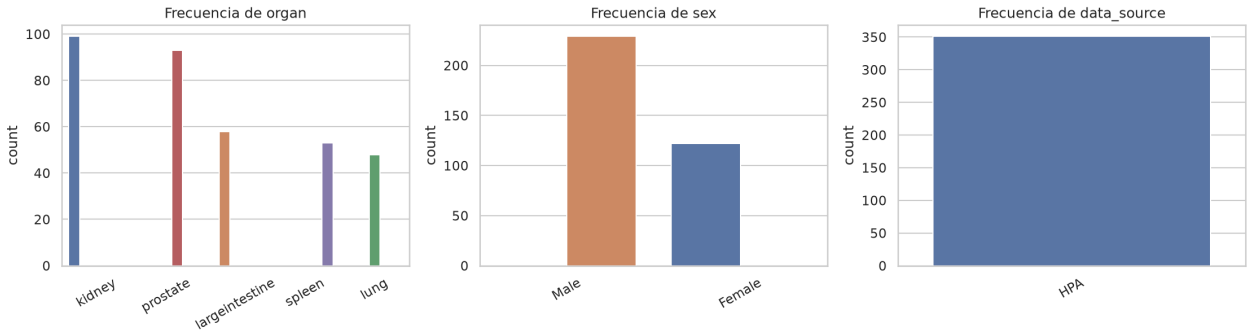


Figura 2: Frecuencia de órgano, sexo y fuente de datos.

Los tres gráficos de barra confirman visualmente lo descrito en las tablas de frecuencia. El caso de `data_source` es particularmente elocuente: una sola barra, porque las 351 filas pertenecen a HPA. La variabilidad entre laboratorios, que constituye la dificultad principal del reto, no se puede observar dentro de estos datos.

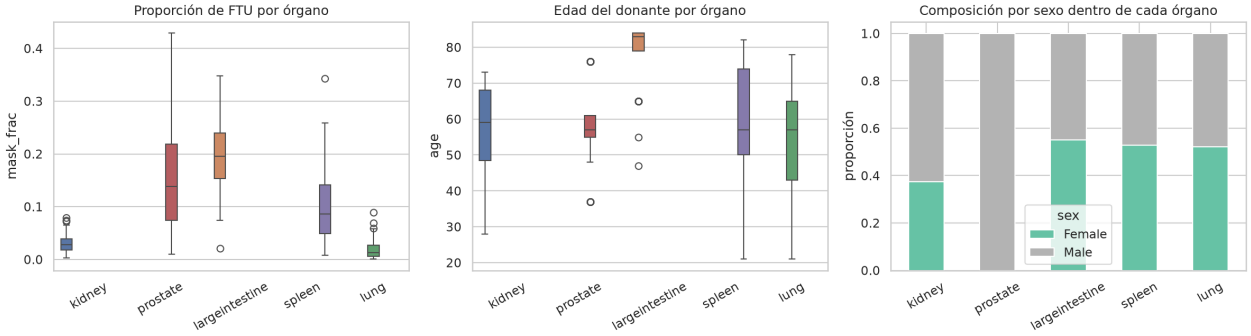


Figura 3: Proporción de FTU por órgano, edad por órgano y composición por sexo dentro de cada órgano.

El primer panel es el más informativo. La proporción de imagen ocupada por la FTU cambia drásticamente según el órgano: en intestino grueso la mediana es de casi 0.20 y en próstata de 0.14, mientras que en pulmón apenas llega a 0.013 y en riñón a 0.028. Es decir, las FTU de pulmón ocupan alrededor de quince veces menos superficie que las de intestino grueso. La dispersión también difiere: próstata y bazo presentan cajas muy anchas y intestino grueso una más compacta. Encontrar la FTU no es el mismo problema en cada órgano.

El segundo panel muestra el caso de intestino grueso, con mediana de 83 años frente a los 57 a 59 de los otros cuatro órganos. El tercero muestra el caso extremo de próstata, 100 % masculino.

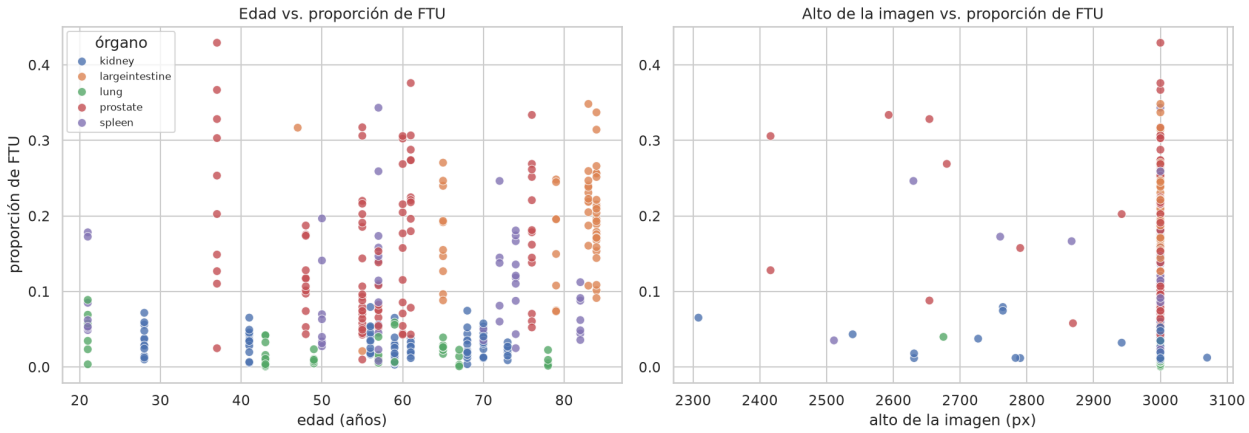


Figura 4: Relación entre edad y proporción de FTU, y entre tamaño de imagen y proporción de FTU, coloreadas por órgano.

El primer gráfico de dispersión contiene el hallazgo más sutil del análisis. Si se calcula la correlación entre edad y proporción de FTU sobre las 351 filas en conjunto, resulta $r = 0{,}248$: una relación positiva débil pero visible, que invitaría a concluir que a mayor edad del donante mayor es el tamaño de la FTU.

Al separar por órgano, esa relación desaparece o se invierte:

Cuadro 10: Correlación entre edad y proporción de FTU, global y por órgano

Grupo	**n**	**r (age, mask_frac)**
Global	351	0,248
kidney	99	−0,178
largeintestine	58	0,139
lung	48	−0,396
prostate	93	0,003
spleen	53	0,028

Lo que ocurre es que la correlación global no mide una relación entre edad y tamaño de FTU, sino que captura el efecto del órgano. Intestino grueso tiene simultáneamente los donantes de mayor edad (mediana de 83 años) y las FTU más grandes (19.6 % de la imagen), de modo que al mezclar todos los órganos en una sola nube ese grupo arrastra la correlación hacia arriba. Se trata de un caso de paradoja de Simpson: la tendencia que aparece en el agregado se contradice al observar cada subgrupo por separado.

La conclusión práctica es doble. Primero, la edad no sirve para anticipar el tamaño de la FTU. Segundo, y más importante, cualquier correlación calculada sobre este conjunto sin estratificar por órgano debe mirarse con desconfianza.

El segundo gráfico confirma que los puntos se apilan casi todos sobre la línea de 3000 px, y que los pocos que quedan a la izquierda son las imágenes recortadas. La correlación entre tamaño de imagen y proporción de FTU es −0,079, prácticamente nula, lo que indica que las imágenes más pequeñas no contienen FTU proporcionalmente más grandes ni más pequeñas. El recorte no introdujo un sesgo

en la variable objetivo.

5.3.9. Exploración visual de las imágenes

Sobre una muestra reducida de `train_images` se decodificó la máscara completa mediante la función inversa del rle y se superpuso sobre el tejido. El análisis visual histórico describió la apariencia del tejido y zonas de fondo blanco, pero el color no identifica la tinción. Estas muestras proceden de HPA, cuya inmunohistoquímica con hematoxilina/DAB se documenta en Jain, Godwin, Joshi et al. (2023); no se confunden con las muestras HuBMAP PAS o H&E.

La máscara superpuesta muestra que las FTU no forman una sola región compacta: en la mayoría de los órganos son varias regiones separadas dentro de la misma imagen, y su forma cambia por completo de un órgano a otro. El contraste entre la FTU y el tejido circundante tampoco es uniforme. En intestino grueso y próstata las estructuras se distinguen a simple vista, mientras que en pulmón y riñón la FTU se confunde mucho más con el tejido de alrededor y ocupa una fracción mínima de la fotografía, lo cual concuerda con lo observado en la distribución de `mask_frac`.

5.3.10. Resumen de hallazgos e implicaciones para el modelado

1. **Variables sin información.** `pixel_size` y `tissue_thickness` son constantes, y `img_height` e `img_width` son iguales entre sí. Ninguna se usó como entrada de los modelos, que solo reciben la imagen.

2. **Desbalance en varios ejes simultáneos**: por órgano (99 riñones contra 48 pulmones), por sexo y por edad, con órgano y edad no independientes. Por eso la división de los datos se estratificó por órgano y las métricas se reportan por órgano.

3. **Variable objetivo fuertemente desbalanceada.** La FTU ocupa en mediana apenas el 5.9 % de la imagen, con 19.6 % en intestino grueso contra 1.3 % en pulmón. Un modelo que predijera fondo en toda la imagen tendría más del 94 % de exactitud por píxel y sería inútil; por eso se usó Dice + BCE como pérdida y Dice e IoU como métricas.

4. **Correlación global espuria.** La relación entre edad y tamaño de FTU es un caso de paradoja de Simpson y obliga a analizar el conjunto por subgrupos.

5. **La generalización entre fuentes no es observable.** Las 351 imágenes son de HPA, así que la variabilidad entre laboratorios se simuló con aumento de datos de color y se agregó el ajuste de tamaño de píxel para imágenes de otras fuentes.

5.4. Entrenamiento y ajuste de parámetros

Los tres modelos se entrenaron con un protocolo común. La comparación es descriptiva de esta ejecución, sin réplicas que permitan atribuir causalmente las diferencias a la arquitectura:

Cuadro 11: Configuración común de entrenamiento

Parámetro	**Valor**
Resolución de entrada	384×384 píxeles
Pesos iniciales	ImageNet (ResNet34) y `nvidia/mit-b0` (SegFormer)
Función de pérdida	$0{,}5 \cdot \text{BCE} + 0{,}5 \cdot (1 - \text{Dice suave})$
Optimizador	AdamW, tasa de aprendizaje 10^{-4}, weight decay 10^{-2}
Batch físico / acumulación	1 imagen, con acumulación de gradientes de 2 pasos (batch efectivo 2)
Precisión	Mixta (AMP) en GPU
Épocas	Máximo 20, con detención temprana de paciencia 5 sobre el Dice de validación
Selección del checkpoint	Época con el mayor Dice de validación
Semilla	42

Ajuste de parámetros. La restricción principal fue la memoria de las GPU portátiles del equipo. Se fijó un perfil conservador que cupiera en la GPU más limitada (6 GB): resolución de 384 px, batch físico de 1 imagen y acumulación de gradientes para obtener un batch efectivo de 2. La acumulación suma los gradientes de dos imágenes antes de actualizar los pesos, de modo que el optimizador ve el equivalente a un batch de 2 sin ocupar la memoria de dos imágenes a la vez. La precisión mixta reduce aún más la memoria y acelera el entrenamiento. La tasa de aprendizaje de 10^{-4} es la habitual para ajustar encoders preentrenados sin destruir lo que aprendieron en ImageNet. La detención temprana se encargó de elegir el número de épocas de cada modelo. Por el tiempo disponible no se hizo una búsqueda sistemática de hiperparámetros; la sección de limitaciones discute qué se cambiaría primero.

Cuadro 12: Resultado del entrenamiento de cada modelo

Modelo	**Parámetros**	**Checkpoint**	**Épocas**	**Mejor época**	**Dice val.**
U-Net / ResNet34	24.4 M	98 MB	13	8	0.606
U-Net++ / ResNet34	26.1 M	105 MB	6	1	0.526
SegFormer / MIT-B0	3.7 M	15 MB	10	5	**0.660**

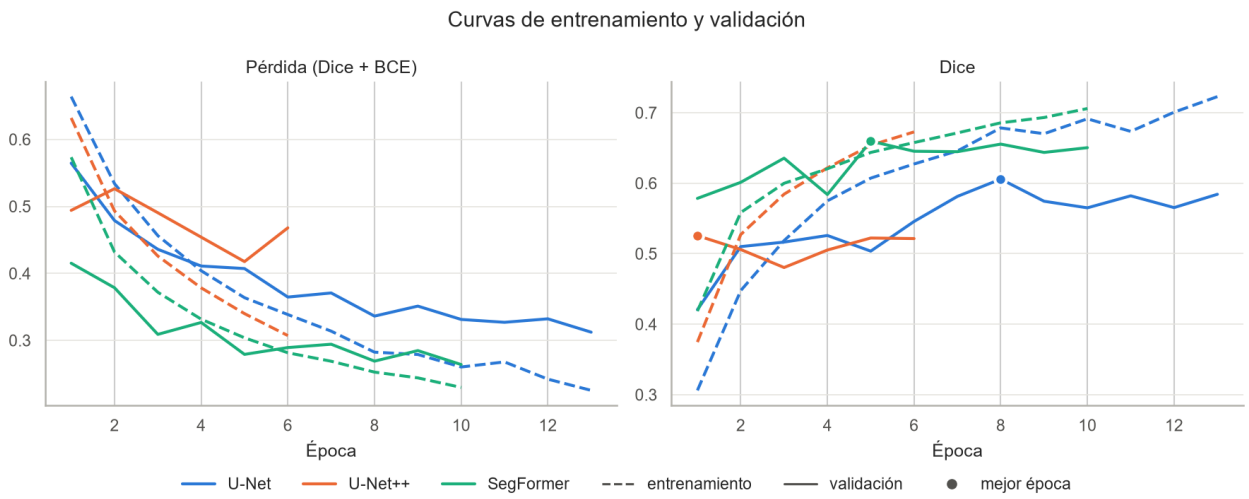


Figura 5: Pérdida y Dice por época de cada modelo, en entrenamiento (punteada) y validación (continua). El punto marca la época con mejor Dice de validación, que es el checkpoint conservado.

Los tres modelos se detuvieron antes de las 20 épocas. SegFormer alcanzó su mejor Dice de validación en la época 5 y U-Net en la 8; en ambos casos la pérdida de entrenamiento siguió bajando mientras la de validación se estabilizó, la señal esperada para detener el entrenamiento. U-Net++ es distinto: su mejor época fue la primera y se detuvo en la sexta, aunque su Dice de entrenamiento subió de 0.37 a 0.67 y su pérdida de entrenamiento bajó de 0.63 a 0.31. El registro demuestra cinco épocas sin superar el mejor Dice de validación, no que el ruido causara la detención ni que se alcanzara el techo de la arquitectura. La variabilidad de validación es una hipótesis que requeriría réplicas. Se ejecutaron 29 épocas en total ($13 + 6 + 10$), frente al máximo conjunto de 60.

5.5. Comparación de los algoritmos

Los modelos se evaluaron una sola vez sobre las 53 imágenes de prueba, que no se usaron ni para entrenar ni para elegir la mejor época. Las métricas se calcularon por imagen con un umbral de 0.5 sobre la probabilidad predicha y luego se promediaron, igual que el Dice de validación. Los tiempos de inferencia se midieron con una imagen a la vez, después de una pasada de calentamiento.

Cuadro 13: Desempeño en el conjunto de prueba (53 imágenes)

Modelo	Dice	IoU	Forward GPU (ms)	Dice val.
SegFormer / MIT-B0	**0.629**	**0.510**	11.6	0.660
U-Net / ResNet34	0.506	0.400	11.8	0.606
U-Net++ / ResNet34	0.481	0.355	31.9	0.526

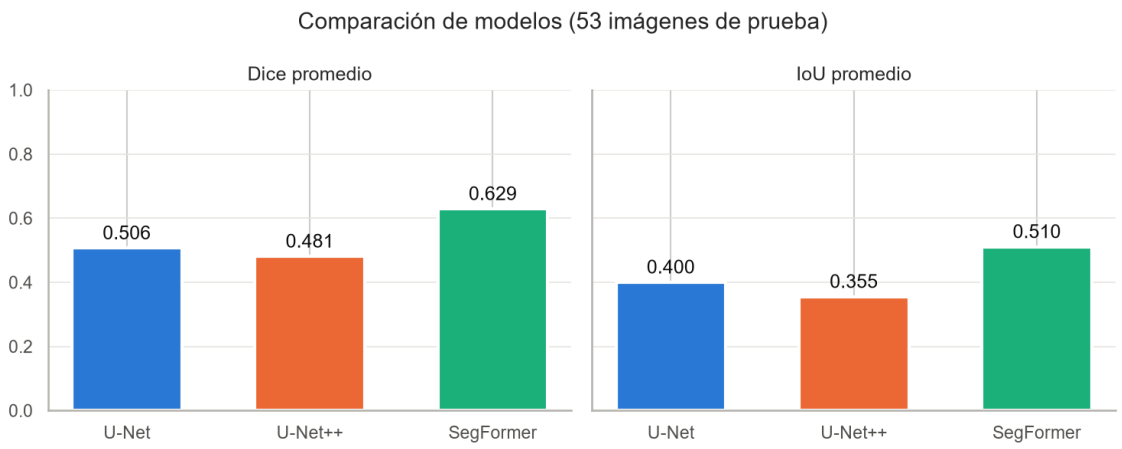


Figura 6: Dice e IoU promedio de cada modelo en el conjunto de prueba.

SegFormer obtiene el mayor Dice (0.629) y el mayor IoU (0.510), con una ventaja de 0.12 de Dice sobre U-Net. Los tres modelos bajan respecto a validación: SegFormer pierde 0.03, U-Net++ 0.045 y U-Net 0.10. La caída de U-Net no permite identificar una causa por sí sola. Los 159 registros comparan los mismos 53 identificadores para cada modelo; cada imagen pesa casi 2 % del promedio. SegFormer presenta la mayor media observada, también por órgano, pero sin réplicas ni intervalos de confianza no se afirma significancia estadística ni superioridad general de la arquitectura.

En tiempo, SegFormer y U-Net son equivalentes en GPU (cerca de 12 ms por imagen), mientras que U-Net++ tarda casi el triple en el registro. Son tiempos de forward en la RTX 4060 Laptop GPU, batch 1, sin carga ni preprocesamiento; no son tiempos CPU ni un benchmark de la demo local.

5.5.1. Desempeño por órgano

Cuadro 14: Dice promedio por órgano en el conjunto de prueba

Órgano	Imágenes	U-Net	U-Net++	SegFormer
kidney	15	0.751	0.504	**0.807**
prostate	14	0.603	0.604	**0.673**
largeintestine	9	0.656	0.687	**0.696**
spleen	8	0.115	0.354	**0.602**
lung	7	0.042	0.061	**0.103**

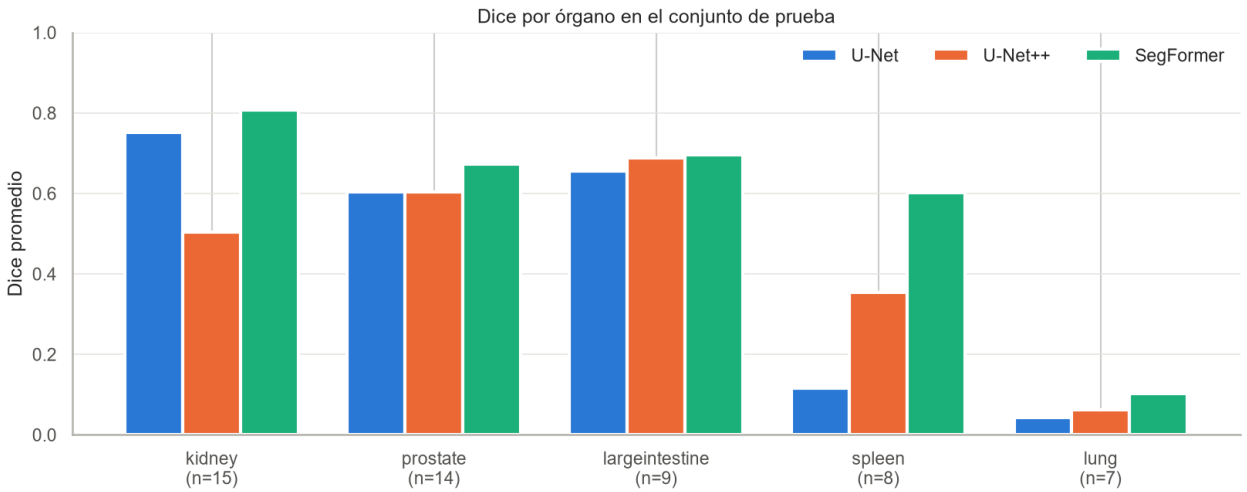


Figura 7: Dice promedio por órgano para cada modelo. Entre paréntesis, la cantidad de imágenes de prueba de cada órgano.

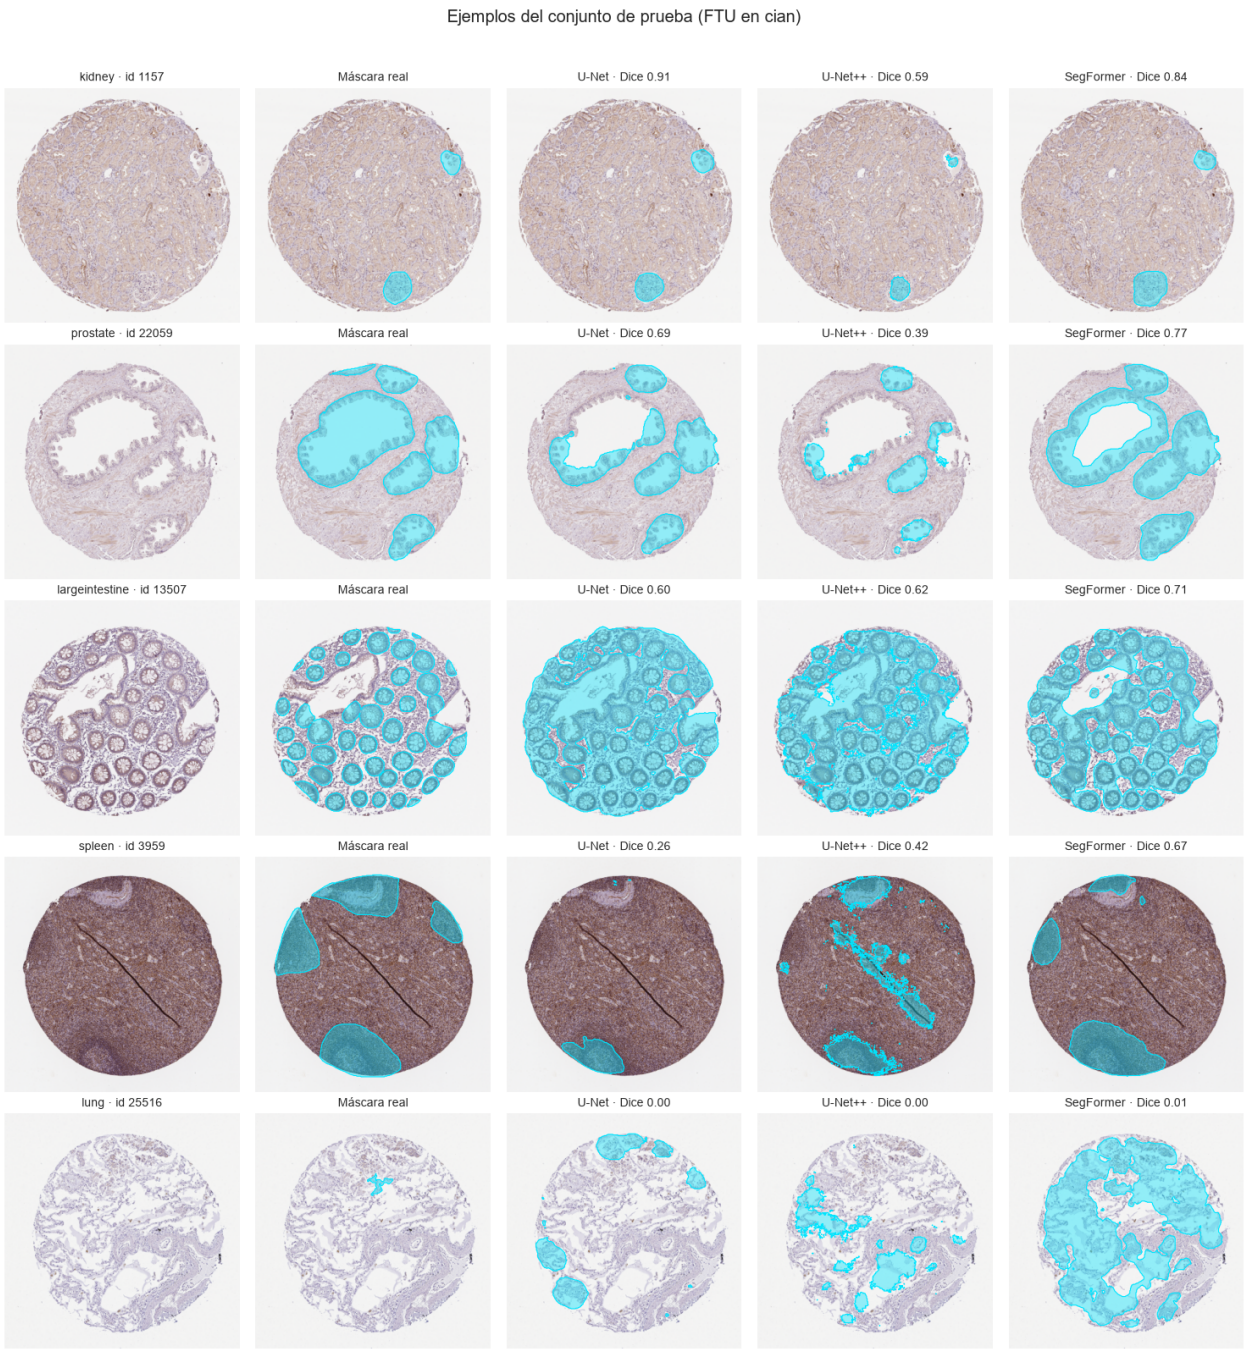


Figura 8: Ejemplos del conjunto de prueba: imagen original, máscara real y predicción de cada modelo, con la FTU en cian. Para cada órgano se eligió la imagen cuyo Dice de SegFormer está más cerca de la mediana de ese órgano, es decir, un caso típico y no el mejor.

El análisis por órgano conecta los resultados con el análisis exploratorio:

- **Riñón (0.81) e intestino grueso (0.70)** son los mejores con SegFormer, igual que en el reto (Jain, Godwin, Joshi et al., 2023). En intestino grueso las criptas ocupan cerca del 19 % de la imagen, la mayor proporción de los cinco órganos, y tienen forma regular. En riñón

los glomérulos ocupan solo el 2.8 %, pero son compactos y redondos, y es el órgano con más imágenes (69 de entrenamiento).

- **Pulmón** es el peor en los tres modelos (Dice 0.042, 0.061 y 0.103); con SegFormer, 4 de sus 7 imágenes de prueba quedan por debajo de 0.1. En el reto también fue el órgano más difícil, aunque los ganadores llegaron a 0.72–0.74 bajo otro protocolo. Como contexto exploratorio, es el órgano con la menor proporción de FTU (mediana de 1.3 %, tabla 9) y con menos imágenes (34 de entrenamiento). En el ejemplo de la figura 8 la máscara real es una región diminuta y los tres modelos marcan zonas grandes de tejido: confunden la estructura alveolar con FTU. Al reducir las imágenes a 384 px, estructuras tan pequeñas quedan en muy pocos píxeles.
- **Bazo** es donde más se separan los modelos: SegFormer llega a 0.60, U-Net++ a 0.35 y U-Net a 0.12. Es de los órganos con menos imágenes y su tejido es muy oscuro, con poco contraste entre la pulpa blanca y la roja. En el ejemplo, U-Net solo detecta una de las regiones y U-Net++ confunde una grieta del tejido con FTU.
- **U-Net++ en riñón (0.50)** queda muy por debajo de U-Net (0.75), a pesar de compartir el encoder. Es consistente con que se quedó con el checkpoint de la época 1.

5.5.2. Selección del modelo

Se selecciona **SegFormer / MIT-B0** como modelo principal de la aplicación:

- Tiene el mayor Dice e IoU en prueba y es el mejor en los cinco órganos.
- Tiene la menor caída observada entre validación y prueba; no se midió estabilidad con réplicas.
- Su forward GPU registrado es 11.6 ms y es el más ligero: 3.7 millones de parámetros y un checkpoint de 15 MB, contra 24 a 26 millones y unos 100 MB de las otras dos arquitecturas.
- Coincide a nivel de familia con la literatura: SegFormer MIT-B4 fue el mejor modelo individual del reto, no la variante MIT-B0 aquí evaluada (Jain, Godwin, Joshi et al., 2023).

5.5.3. Limitaciones

- **Una ejecución por arquitectura.** U-Net++ ejecutó seis épocas y conservó la primera. No se demostró que estuviera subestimado ni que el ruido explicara su resultado.
- **El conjunto de prueba es pequeño**: 53 imágenes en total y entre 7 y 15 por órgano. Una imagen mueve el promedio general casi 2 % y el de pulmón 14 %.
- **La comparación con los ganadores** (Dice $\approx$ 0.835) usa conjuntos y protocolos diferentes. Hay diferencias en el perfil de entrenamiento: 384 px en lugar de resoluciones mayores, batch efectivo de 2, un solo modelo por arquitectura, la variante más pequeña de SegFormer (MIT-B0 contra MIT-B4) y sin datos externos, ensambles ni pseudo-etiquetado, pero no se aislaron sus efectos ni se probaron causas.
- **Solo hay imágenes de HPA**, así que no se pudo medir el desempeño sobre muestras de HuBMAP, que es la dificultad central del reto.

- **Partición por imagen.** No se verificó independencia por donante; no se descarta dependencia entre muestras de una misma persona.
- **Activos ausentes en la entrega local.** Los pesos, `train.csv` y la caché no están disponibles. Esto limita reproducir la inferencia y el EDA completo, sin invalidar los CSV y las figuras históricos conservados. El prototipo no tiene validación clínica.

Las mejoras más directas serían entrenar U-Net++ con más paciencia o un batch efectivo mayor, usar parches a mayor resolución para el pulmón y probar una variante más grande de SegFormer.

5.6. Aplicación

Se construyó una aplicación web con Streamlit y gráficas interactivas de Plotly. Streamlit permite una interfaz en Python que integra el pipeline de inferencia del proyecto, y se ejecuta localmente con un solo comando (`uv run streamlit run app/Inicio.py`). Plotly ofrece gráficas con información al pasar el cursor, zoom y filtros, que son las gráficas interactivas que pide la aplicación.

La aplicación tiene cuatro páginas y no ejecuta una nueva evaluación del conjunto de prueba:

- **Inicio.** Resumen de los modelos y avisos de activos ausentes.
- **Exploración de los datos.** Sin `train.csv`, muestra únicamente los metadatos disponibles de `splits.csv`: órgano y partición, con filtros. Las vistas de fuente, sexo, edad, dimensiones y cobertura requieren recuperar los metadatos; no se inventan.
- **Predicción.** Acepta exclusivamente imágenes nuevas PNG, JPEG o TIFF de una sola imagen, hasta 64 MiB y nueve millones de píxeles. Con checkpoints confiables permitiría seleccionar uno o todos los modelos disponibles. Convierte a RGB, redimensiona a 384×384, normaliza con ImageNet y aplica el umbral fijo $\geq 0{,}5$. Asume $0.4\,\mu\text{m}$/píxel sin ajuste físico configurable. La salida es una máscara binaria de FTU, no una clasificación de órgano; la selección de órgano es información descriptiva. Restaura la máscara al tamaño original y muestra superposición, área FTU y tiempo CPU. No ofrece selector de prueba, máscara real ni Dice/IoU para cargas sin anotaciones. Actualmente la inferencia está bloqueada por ausencia de los tres checkpoints.
- **Rendimiento de los modelos.** Gráficas interactivas de Dice, IoU, Dice por órgano, distribución del Dice por imagen, tiempos de inferencia y curvas de entrenamiento, que el usuario puede mostrar u ocultar. Reutiliza 159 filas de métricas (53 imágenes comunes), los historiales y los experimentos existentes; los filtros de órgano no alteran las curvas globales. El control de ocultamiento persiste al navegar a Inicio.

La aplicación usa los mismos colores que las figuras de este informe para cada modelo (azul para U-Net, naranja para U-Net++ y verde para SegFormer), elegidos para distinguirse también con las formas más comunes de daltonismo, con etiquetas y estilos de línea adicionales. El cian identifica las máscaras y contrasta con la tinción; no se afirma una auditoría formal de accesibilidad.

Las capturas de la entrega deben corresponder a la aplicación local sin alterar datos ni simular predicciones. El estado bloqueado es parte de la evidencia, no una inferencia exitosa.



Figura 9: Inicio de la aplicación local: resultados históricos y aviso de activos ausentes. Captura auténtica del 11 de octubre de 2026.

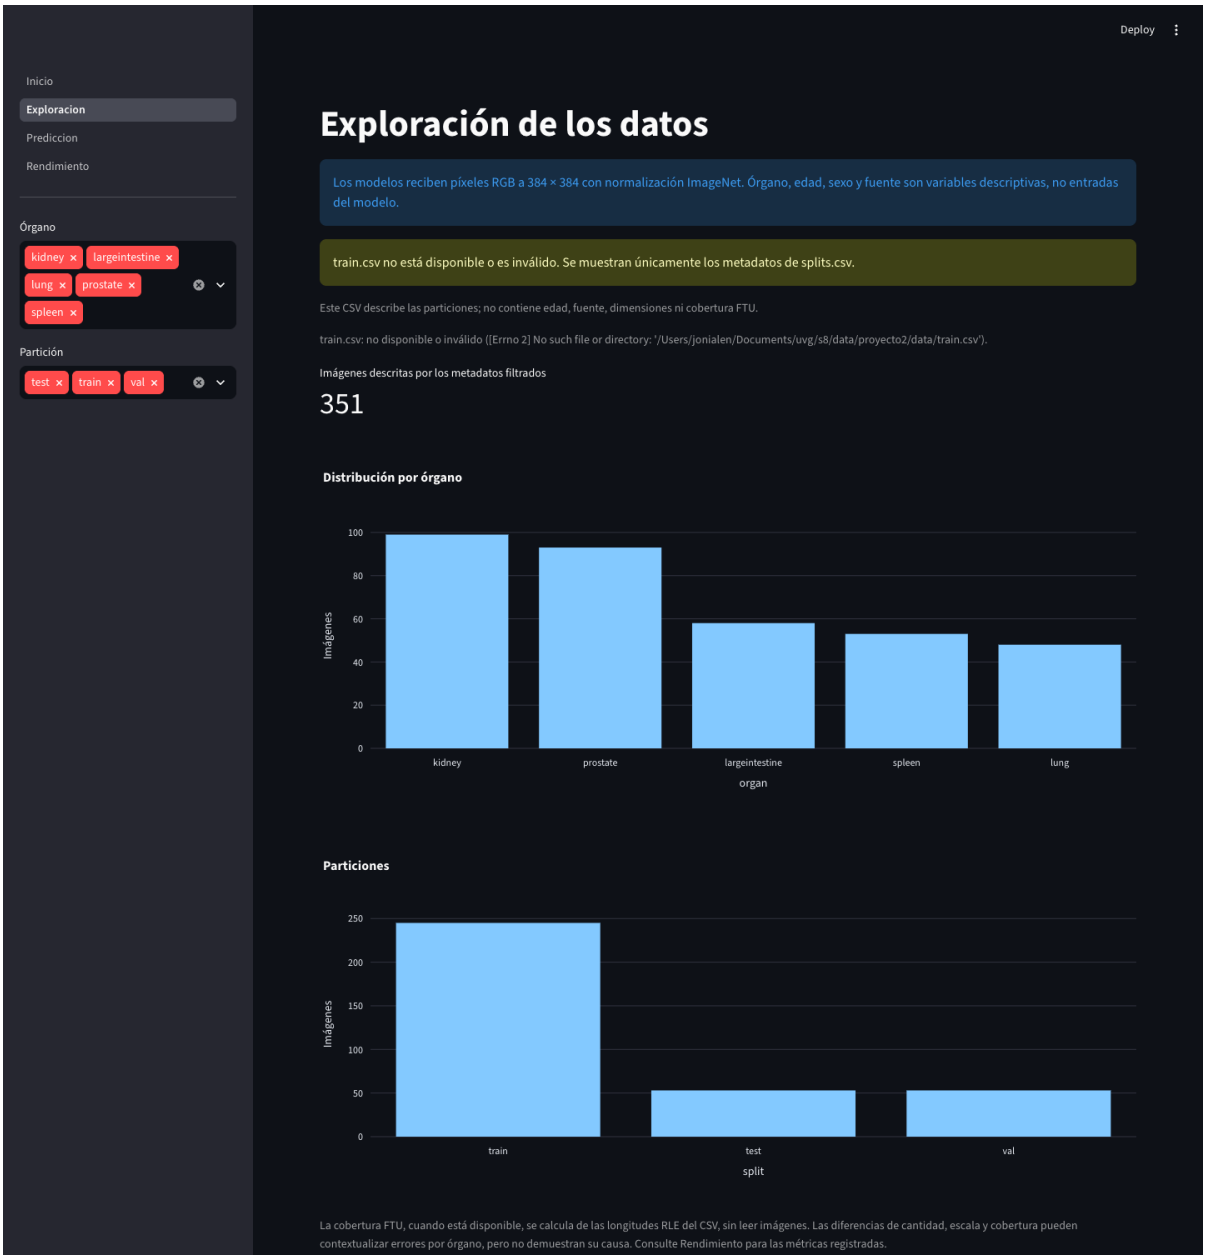


Figura 10: Exploración local con 351 metadatos de partición; `train.csv` está ausente. Captura auténtica del 11 de octubre de 2026, sin carga de imágenes.

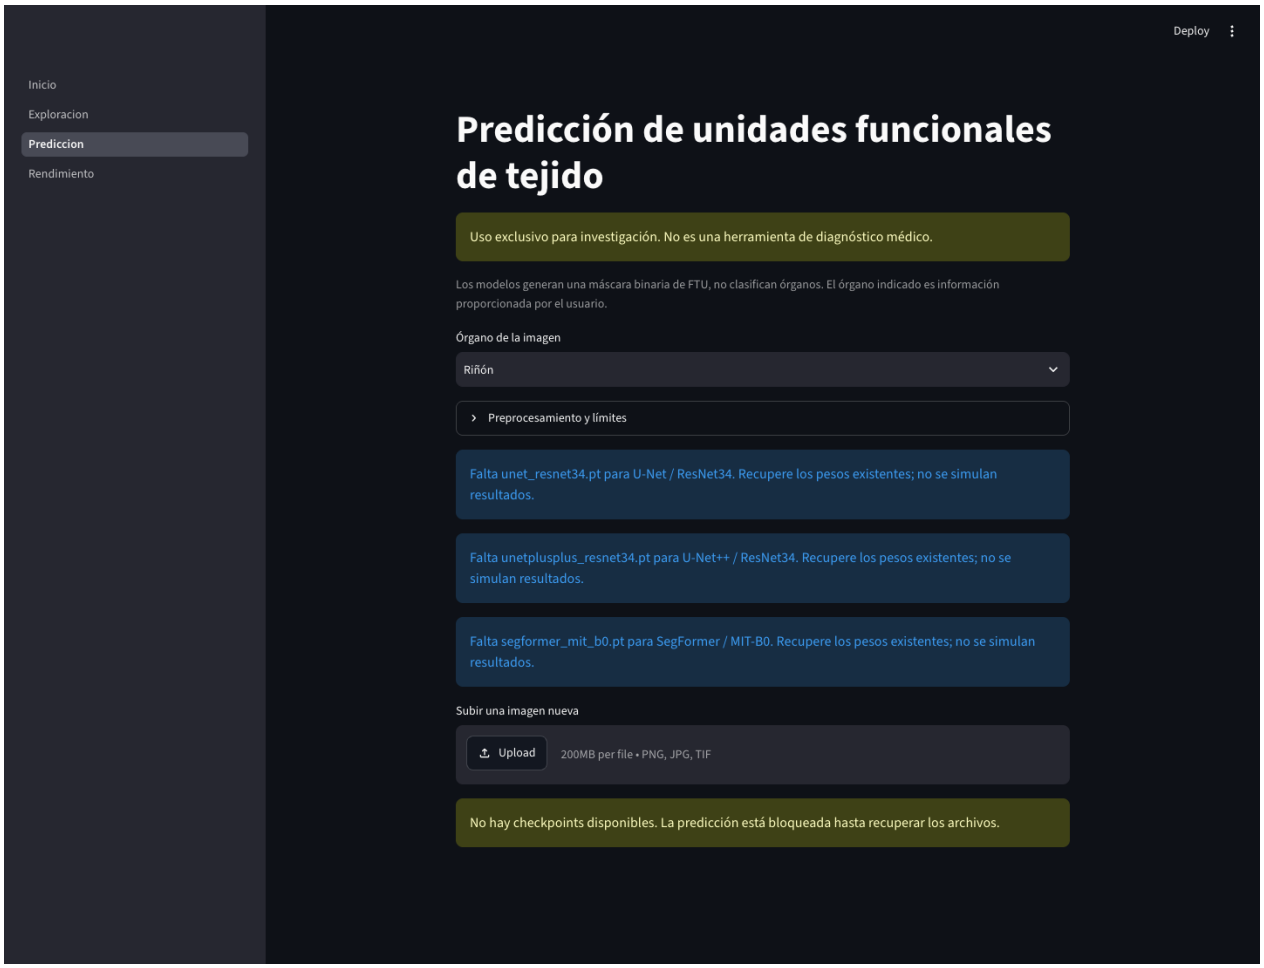


Figura 11: Predicción bloqueada por checkpoints ausentes. No hay una máscara simulada ni una inferencia real. Captura auténtica del 11 de octubre de 2026.

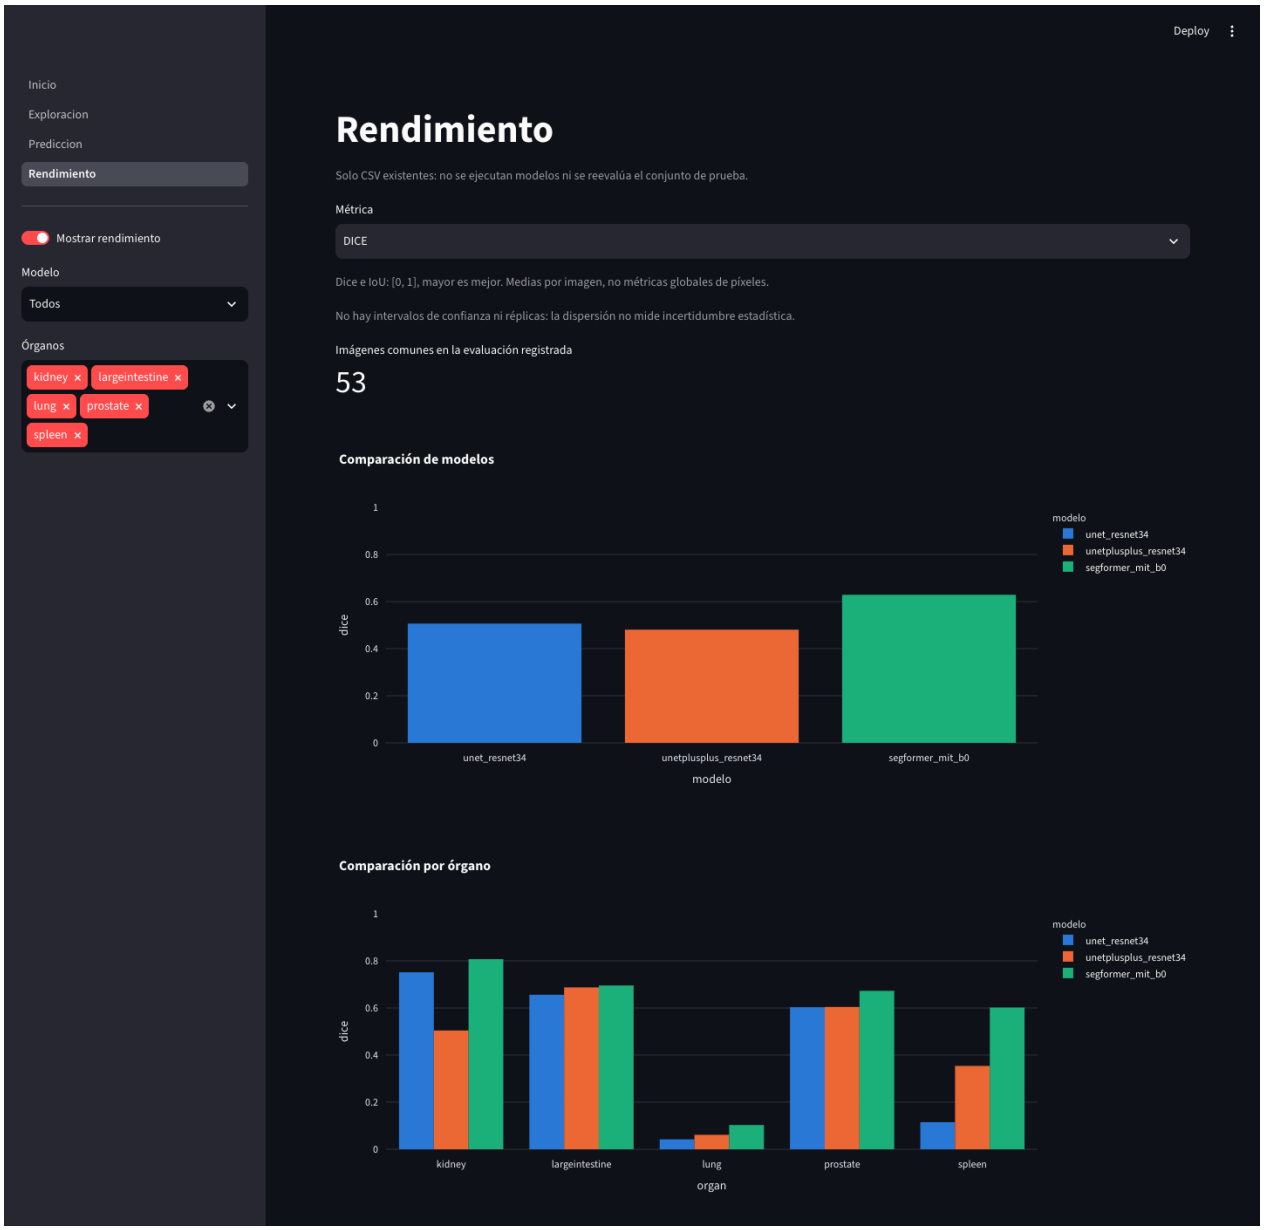


Figura 12: Vista de rendimiento: 53 identificadores comunes, filtros y control de ocultamiento. Solo resultados CSV existentes; captura auténtica del 11 de octubre de 2026.

6. Conclusiones

1. **Exploración de los datos.** El análisis exploratorio mostró que la variable objetivo está fuertemente desbalanceada (la FTU ocupa en mediana el 5.9 % de la imagen), que ese desbalance cambia mucho entre órganos (de 19.6 % en intestino grueso a 1.3 % en pulmón) y que el conjunto de entrenamiento solo contiene imágenes de HPA. Estos hallazgos guiaron las decisiones posteriores: estratificar por órgano, usar Dice + BCE y simular la variabilidad de tinción con aumento de datos.

2. **Preprocesamiento.** Se construyó un pipeline reutilizable que decodifica las máscaras (verifi-

cado en las 351 imágenes), ajusta el tamaño de píxel, redimensiona a 384 px y aplica aumento de datos. El pipeline de inferencia reproduce la conversión y la transformación de validación para cargas nuevas, asumiendo el espaciado de referencia.

3. **Modelos.** Se seleccionaron y entrenaron tres arquitecturas a partir de la revisión bibliográfica: U-Net, U-Net++ y SegFormer, con un protocolo común que cabe en una GPU portátil de 6 GB.

4. **Evaluación y selección.** SegFormer / MIT-B0 fue el mejor modelo en el conjunto de prueba (Dice de 0.629 e IoU de 0.510), el mejor observado en los cinco órganos y el más ligero, por lo que se seleccionó como referencia de la aplicación. No se probó superioridad general ni significancia estadística. El resultado coincide con la literatura sobre el reto. El pulmón fue el órgano más difícil para los tres modelos; el EDA aporta contexto, no demuestra la causa.

5. **Aplicación.** Se desarrolló una aplicación en Streamlit que permite explorar los datos, comparar los resultados históricos y ocultarlos con un control persistente. La implementación de cargas nuevas está completa y verificada con pruebas sintéticas, pero no se pudo aceptar la inferencia con pesos entrenados ausentes. Por tanto, el objetivo de segmentar imágenes nuevas de extremo a extremo está pendiente, no se declara cumplido en esta entrega sin pesos.

Sobre la efectividad de los algoritmos: los modelos segmentan bien los órganos con FTU grandes o de forma regular (riñón, intestino grueso y próstata, con Dice de 0.67 a 0.81 para SegFormer), pero no son confiables en pulmón. La comparación con las soluciones ganadoras no permite probar las causas de la diferencia: en el reto, un SegFormer más grande (MIT-B4), entrenado a mayor resolución y con datos externos, llegó por sí solo a un Dice de 0.828 (Jain, Godwin, Joshi et al., 2023).

Esta entrega conserva los resultados históricos y sus figuras sin reevaluación ni entrenamiento. Los pesos podrán añadirse después desde una fuente confiable; su recuperación fue diferida por el equipo. El sistema es un prototipo de investigación, no una herramienta de diagnóstico.

Referencias

Bidanta, S., Börner, K., Herr, B. W., II, Quardokus, E. M., Nagy, M., Gustilo, K. S., Bajema, R., Maier, E., Molontay, R., & Weber, G. M. (2025). Functional tissue units in the Human Reference Atlas. *Nature Communications*, *16*, Artículo 1526. https://doi.org/10.1038/s41467-024-54591-6

Chen, L.-C., Zhu, Y., Papandreou, G., Schroff, F., & Adam, H. (2018). Encoder-decoder with atrous separable convolution for semantic image segmentation. *Computer Vision – ECCV 2018*, *11211*, 833-851. https://doi.org/10.1007/978-3-030-01234-2_49

de Bono, B., Grenon, P., Baldock, R., & Hunter, P. (2013). Functional tissue units and their primary tissue motifs in multi-scale physiology. *Journal of Biomedical Semantics*, *4*(1), Artículo 22. https://doi.org/10.1186/2041-1480-4-22

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770-778. https://doi.org/10.1109/CVPR.2016.90

HuBMAP Consortium. (2019). The human body at cellular resolution: The NIH Human Biomolecular Atlas Program. *Nature*, *574*(7777), 187-192. https://doi.org/10.1038/s41586-019-1629-x

Isensee, F., Jaeger, P. F., Kohl, S. A. A., Petersen, J., & Maier-Hein, K. H. (2021). nnU-Net: A self-configuring method for deep learning-based biomedical image segmentation. *Nature Methods*, *18*(2), 203-211. https://doi.org/10.1038/s41592-020-01008-z

Jain, Y., Godwin, L. L., Joshi, S., Mandarapu, S., Le, T., Lindskog, C., Lundberg, E., & Börner, K. (2023). Segmenting functional tissue units across human organs using community-driven development of generalizable machine learning algorithms. *Nature Communications*, *14*, Artículo 4656. https://doi.org/10.1038/s41467-023-40291-0

Jain, Y., Godwin, L. L., Ju, Y., Sood, N., Quardokus, E. M., Bueckle, A., Longacre, T., Horning, A., Lin, Y., Esplin, E. D., Hickey, J. W., Snyder, M. P., Patterson, N. H., Spraggins, J. M., & Börner, K. (2023). Segmentation of human functional tissue units in support of a Human Reference Atlas. *Communications Biology*, *6*, Artículo 717. https://doi.org/10.1038/s42003-023-04848-5

Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M., van der Laak, J. A. W. M., van Ginneken, B., & Sánchez, C. I. (2017). A survey on deep learning in medical image analysis. *Medical Image Analysis*, *42*, 60-88. https://doi.org/10.1016/j.media.2017.07.005

Loshchilov, I., & Hutter, F. (2019). Decoupled weight decay regularization. *International Conference on Learning Representations (ICLR)*. https://openreview.net/forum?id=Bkg6RiCqY7

Macenko, M., Niethammer, M., Marron, J. S., Borland, D., Woosley, J. T., Guan, X., Schmitt, C., & Thomas, N. E. (2009). A method for normalizing histology slides for quantitative analysis. *2009 IEEE International Symposium on Biomedical Imaging: From Nano to Macro*, 1107-1110. https://doi.org/10.1109/ISBI.2009.5193250

Milletari, F., Navab, N., & Ahmadi, S.-A. (2016). V-Net: Fully convolutional neural networks for volumetric medical image segmentation. *2016 Fourth International Conference on 3D Vision (3DV)*, 565-571. https://doi.org/10.1109/3DV.2016.79

Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, *9351*, 234-241. https://doi.org/10.1007/978-3-319-24574-4_28

Siddique, N., Paheding, S., Elkin, C. P., & Devabhaktuni, V. (2021). U-Net and its variants for medical image segmentation: A review of theory and applications. *IEEE Access*, *9*, 82031-82057. https://doi.org/10.1109/ACCESS.2021.3086020

Tellez, D., Litjens, G., Bándi, P., Bulten, W., Bokhorst, J.-M., Ciompi, F., & van der Laak, J. (2019). Quantifying the effects of data augmentation and stain color normalization in convolutional neural networks for computational pathology. *Medical Image Analysis*, *58*, Artículo 101544. https://doi.org/10.1016/j.media.2019.101544

Xie, E., Wang, W., Yu, Z., Anandkumar, A., Alvarez, J. M., & Luo, P. (2021). SegFormer: Simple and efficient design for semantic segmentation with transformers. En M. Ranzato, A. Beygelzimer, Y. Dauphin, P. S. Liang & J. Wortman Vaughan (Eds.), *Advances in Neural Information Processing Systems* (pp. 12077-12090, Vol. 34). Curran Associates, Inc. https://proceedings.neurips.cc/paper/2021/hash/64f1f27bf1b4ec22924fd0acb550c235-Abstract.html

Xu, W., Xu, Y., Chang, T., & Tu, Z. (2021). Co-scale conv-attentional image transformers. *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*, 9961-9970. https://doi.org/10.1109/ICCV48922.2021.00983

Zhou, Z., Siddiquee, M. M. R., Tajbakhsh, N., & Liang, J. (2020). UNet++: Redesigning skip connections to exploit multiscale features in image segmentation. *IEEE Transactions on Medical Imaging*, *39*(6), 1856-1867. https://doi.org/10.1109/TMI.2019.2959609

Repositorio

El código, el cuaderno de análisis y las fuentes de este informe están versionados en:

https://github.com/AleWWH1104/proyecto2-data