

Proyecto 2. Análisis Exploratorio

Reto 18: Hackeando el cuerpo humano
HuBMAP + HPA — Segmentación de unidades funcionales de tejido

Iris Ayala — 23965 Jonatan Díaz — 23837 Angie Quezada — 23643

Universidad del Valle de Guatemala
Facultad de Ingeniería — Departamento de Ciencias de la Computación
CC3084 Data Science — Semestre II, 2026

7 de septiembre de 2026

Resumen

Este informe presenta el análisis exploratorio del conjunto de datos de la competencia *HuBMAP - Hacking the Human Body*, cuyo objetivo es segmentar unidades funcionales de tejido (FTU) en imágenes de cortes histológicos de cinco órganos humanos. Se analizaron las 351 observaciones del archivo `train.csv`, se construyó una variable derivada a partir de la máscara codificada en *run-length encoding* y se documentaron los hallazgos que condicionan cualquier intento posterior de modelado. Los resultados principales son la ausencia total de muestras HuBMAP en el conjunto de entrenamiento, la existencia de variables numéricas constantes, un desbalance simultáneo en órgano, sexo y edad, una variable objetivo fuertemente desbalanceada a nivel de píxel, y una correlación global entre edad y tamaño de FTU que se revela espuria al controlar por órgano.

Índice

1. Investigación del tema	2
1.1. Sobre el diagnóstico basado en imágenes	2
2. Análisis del problema planteado y los datos	2
2.1. Situación problemática	2
2.2. Problema científico	3
2.3. Objetivos	3
3. Descripción de los datos y limpieza	3
3.1. Origen y estructura	3
3.2. Limpieza y preprocesamiento	4
4. Análisis exploratorio	4
4.1. Variables y observaciones disponibles	4
4.2. Resumen de las variables numéricas	5

4.3. Tablas de frecuencia de las variables categóricas	5
4.4. Cruce de variables	6
4.5. Correlaciones	6
4.6. Outliers y valores faltantes	7
4.7. Variable derivada: área de la FTU	7
4.8. Gráficos exploratorios	8
4.8.1. Gráficos univariados	8
4.8.2. Gráficos de barra de las variables categóricas	9
4.8.3. Cruces gráficos	9
4.8.4. Gráficos de dispersión	10
4.9. Exploración visual de las imágenes	11
5. Hallazgos y conclusiones	11
5.1. Resumen de hallazgos	11
5.2. Conclusiones sobre los siguientes pasos	12
Repositorio	12

1. Investigación del tema

HuBMAP (*Human BioMolecular Atlas Program*) es un programa que busca mapear el cuerpo humano a nivel de célula, es decir, construir un mapa detallado de cómo están organizados los tejidos sanos en cada órgano. La competencia de Kaggle nace de ese programa y combina datos de HuBMAP con los del Atlas de Proteínas Humanas (HPA). Lo que pide es encontrar y delimitar, dentro de fotografías de tejido, las llamadas unidades funcionales de tejido o FTU.

Una FTU es un grupo pequeño de células organizadas alrededor de un vaso sanguíneo que en conjunto cumplen una función específica dentro del órgano al que pertenecen. El reto incluye cinco órganos: riñón, próstata, bazo, pulmón e intestino grueso. En cada uno la FTU se ve distinta porque cada órgano tiene su propia estructura: en riñón corresponde a los glomérulos, en intestino grueso a las criptas, en próstata a las unidades glandulares.

1.1. Sobre el diagnóstico basado en imágenes

Las imágenes provienen de cortes de tejido teñidos con PAS (*Periodic Acid-Schiff*), una tinción que reacciona con los carbohidratos del tejido y resalta membranas basales y estructuras glandulares, de modo que puedan distinguirse al microscopio. Ese es el motivo del característico tono rosado y morado de las muestras.

El patrón que un algoritmo debe reconocer no es una lesión ni una enfermedad, sino una estructura anatómica normal: la organización espacial de células alrededor de un vaso. La dificultad diagnóstica está en que esa organización cambia de forma, tamaño y contraste según el órgano, y en que la apariencia del tejido depende también de cómo se preparó y escaneó la muestra.

Como los datos provienen de dos fuentes distintas, y cada una prepara y escanea las muestras a su manera, un mismo órgano puede verse diferente según de dónde salió la imagen. Este punto es central: la meta es que el modelo reconozca las FTU sin importar el órgano ni la fuente, y no que memorice los casos que vio durante el entrenamiento.

2. Análisis del problema planteado y los datos

2.1. Situación problemática

Actualmente, identificar las unidades funcionales de tejido en una imagen de biopsia lo hacen patólogos a mano, revisando la muestra al microscopio y marcando dónde están esas estructuras. El procedimiento toma tiempo, depende de la experiencia de la persona que lo realiza y no es escalable a miles de imágenes de distintos órganos.

A eso se suma un problema de consistencia: como las muestras pueden venir de laboratorios distintos con procesos de preparación distintos, dos imágenes del mismo órgano no siempre se ven igual. Esto complica todavía más hacer el trabajo de forma manual y reproducible, e introduce variabilidad entre observadores que es difícil de cuantificar.

2.2. Problema científico

El problema se formula como una tarea de segmentación semántica: a partir de una imagen de tejido, ¿se puede entrenar un modelo que marque con precisión en qué zonas de la imagen se encuentran las unidades funcionales de tejido, sin importar de qué órgano se trate ni de qué fuente provenga la muestra?

La dificultad adicional es que el conjunto de datos solo contiene unos cuantos órganos y fuentes, de manera que el modelo debe aprender un patrón que generalice en lugar de memorizar la apariencia particular de cada órgano.

2.3. Objetivos

Objetivo general. Explorar y describir los datos de la competencia HuBMAP para entender cómo están compuestas las imágenes de tejido y las variables que las acompañan, de forma que sirva de base para plantear una futura solución al problema de segmentación de FTU.

Objetivos específicos.

1. Describir las variables numéricas y categóricas del conjunto de datos (órgano, fuente, edad, sexo, grosor del tejido, dimensiones de imagen) y detectar diferencias entre grupos.
2. Analizar cómo se relacionan órgano, fuente de datos, edad y sexo, para identificar qué tan variadas son las imágenes según esos factores.
3. Cuantificar el área que ocupa la FTU dentro de cada imagen y comparar su distribución entre órganos, para dimensionar el desbalance de clases del problema de segmentación.

3. Descripción de los datos y limpieza

3.1. Origen y estructura

Se trabajó únicamente con el archivo `train.csv`, que es el único que trae etiquetas completas, ya que no se participó en la competencia como tal. El archivo tiene 351 filas y 10 columnas. Cada fila corresponde a una imagen de tejido con su información asociada.

Cuadro 1: Variables disponibles en `train.csv`

Variable	Tipo	Descripción
<code>id</code>	Identificador	Código de la imagen. Sin valor analítico propio.
<code>organ</code>	Categórica	Órgano de la muestra (5 niveles).
<code>data_source</code>	Categórica	Fuente de la muestra (HuBMAP o HPA).
<code>img_height</code>	Numérica	Alto de la imagen en píxeles.
<code>img_width</code>	Numérica	Ancho de la imagen en píxeles.
<code>pixel_size</code>	Numérica	Micrómetros representados por cada píxel.
<code>tissue_thickness</code>	Numérica	Grosor del corte de tejido.
<code>rle</code>	Texto	Máscara de la FTU codificada en run-length encoding.
<code>age</code>	Numérica	Edad del donante en años.
<code>sex</code>	Categórica	Sexo del donante.

La columna `rle` merece una aclaración porque no es una variable convencional. El formato *run-length encoding* no almacena la máscara píxel por píxel, sino pares de números (posición inicial, longitud) que indican tramos consecutivos de píxeles marcados. Guardar una máscara de 3000×3000 como matriz sería inviable dentro de una celda de texto; el `rle` la comprime a unos cuantos miles de caracteres.

3.2. Limpieza y preprocesamiento

No se encontraron valores nulos ni filas duplicadas en `train.csv`, de modo que no fue necesario eliminar ni imputar ninguna observación. La única operación aplicada fue convertir `organ`, `data_source` y `sex` a tipo categórico, ya que pandas las cargaba como texto plano y el tipo categórico las identifica correctamente como conjuntos cerrados de valores.

La columna `rle` no se decodifica de forma completa para todo el conjunto, porque reconstruir 351 máscaras de nueve millones de píxeles cada una es costoso y no aporta nada al análisis tabular. La decodificación completa se reserva para la muestra de imágenes usada en la sección visual.

4. Análisis exploratorio

4.1. Variables y observaciones disponibles

El conjunto tiene 351 observaciones, una por imagen de tejido, y 10 variables. Tres son categóricas (`organ`, `data_source`, `sex`), cinco son numéricas (`img_height`, `img_width`, `pixel_size`, `tissue_thickness`, `age`), una es un identificador (`id`) y una es texto estructurado (`rle`). No hay valores faltantes en ninguna de las 351 filas.

4.2. Resumen de las variables numéricas

Cuadro 2: Estadísticos descriptivos de las variables numéricas

	media	desv. est.	mín	Q1	mediana	máx
<code>img_height</code>	2978.4	91.0	2308	3000	3000	3070
<code>img_width</code>	2978.4	91.0	2308	3000	3000	3070
<code>pixel_size</code>	0.4	0.0	0.4	0.4	0.4	0.4
<code>tissue_thickness</code>	4.0	0.0	4	4	4	4
<code>age</code>	60.4	16.0	21	55	60	84

Casi todas las imágenes miden 3000×3000 píxeles: la mediana y el percentil 75 de `img_height` e `img_width` caen exactamente en 3000, y el mínimo de 2308 indica que existen algunas imágenes más pequeñas, aunque la variación es baja frente al tamaño típico (desviación estándar de aproximadamente 91 píxeles). Además, en las 351 filas el alto y el ancho coinciden siempre, es decir que todas las imágenes son cuadradas.

`pixel_size` y `tissue_thickness` no varían en absoluto: valen 0.4 y 4 en las 351 filas, con desviación estándar cero. En este archivo no aportan ninguna información para diferenciar observaciones. La explicación aparece en la tabla de frecuencias de la sección siguiente: `train.csv` solo contiene imágenes de origen HPA, que se escanean siempre con esos mismos parámetros. En el conjunto de HuBMAP estos valores sí varían.

En cuanto a `age` hay dispersión considerable: el promedio es de 60 años, con donantes entre 21 y 84 años y una desviación estándar de 16 años, lo que indica que el conjunto cubre un rango amplio de edades adultas.

4.3. Tablas de frecuencia de las variables categóricas

Cuadro 3: Distribución de las variables categóricas

Variable	Nivel	Frecuencia	Proporción
<code>organ</code>	kidney	99	28.2 %
	prostate	93	26.5 %
	largeintestine	58	16.5 %
	spleen	53	15.1 %
	lung	48	13.7 %
<code>data_source</code>	HPA	351	100.0 %
	HuBMAP	0	0.0 %
<code>sex</code>	Male	229	65.2 %
	Female	122	34.8 %

En `organ`, riñón (99) y próstata (93) son los órganos con más observaciones, seguidos de intestino grueso (58), bazo (53) y pulmón (48, el menos representado). No es un desbalance extremo, pero conviene tenerlo en cuenta al comparar métricas entre órganos.

En `data_source`, el 100 % de las filas provienen de HPA: no hay ninguna observación de HuBMAP en `train.csv`. Este es un hallazgo importante. Aunque la competencia combina ambas fuentes, el archivo con el que se trabaja solo contiene la parte pública de HPA, mientras que las muestras de HuBMAP quedan en el conjunto de prueba oculto. En consecuencia, este análisis describe solo esa porción de los datos y no el problema completo.

En `sex`, el 65.2 % de los donantes son hombres (229) y el 34.8 % mujeres (122). Este desbalance se explica en parte por `prostate`, que por razones biológicas solo tiene donantes hombres, como se revisa en el cruce de variables.

4.4. Cruce de variables

Cuadro 4: Tabla de contingencia entre órgano y sexo

Órgano	Female	Male	% Male
kidney	37	62	62.6 %
prostate	0	93	100.0 %
largeintestine	32	26	44.8 %
spleen	28	25	47.2 %
lung	25	23	47.9 %

El cruce de `organ` con `sex` explica buena parte del desbalance de sexo: `prostate` es 100 % masculino (93 de 93), lo cual es un patrón esperado por la biología del órgano y no un error de datos. `kidney` también se inclina hacia hombres (63 %), mientras que intestino grueso, pulmón y bazo están bastante más parejos (45 a 55 %). Como próstata es el segundo órgano más frecuente, entre ese y riñón explican casi todo el desbalance general observado.

El cruce de `organ` con `age` muestra que `largeintestine` es un caso claramente distinto: su edad mediana es de 83 años, muy por encima de los otros cuatro órganos, que rondan entre 53 y 60 años de mediana. Esto indica que `organ` y `age` no son independientes en este conjunto. No parece un error, sino el resultado de cómo se repartieron los donantes por tipo de muestra, pero es importante tenerlo presente: cualquier patrón que se observe en `age` puede en realidad estar reflejando de qué órgano proviene la imagen.

4.5. Correlaciones

La matriz de correlación no muestra relaciones lineales relevantes entre las variables numéricas originales. La correlación entre `age` e `img_height` o `img_width` es prácticamente nula (0.04), y con `id` también (0.02, esperable porque `id` es solo un identificador sin significado real). `img_height` e `img_width` correlacionan perfectamente entre sí (1.0), lo cual tiene sentido porque todas las imágenes son cuadradas.

`pixel_size` y `tissue_thickness` aparecen como NaN en toda la matriz. Esto no es un error de cálculo: al ser constantes, su desviación estándar es cero y el coeficiente de Pearson queda indefinido porque implica una división entre cero. Dentro de las variables numéricas originales no hay pares que valga la pena modelar juntos por una relación lineal; lo interesante del conjunto está en las categóricas y en sus cruces.

4.6. Outliers y valores faltantes

En `age`, el método del rango intercuartílico marca 13 outliers (límites de 28 a 100 años), todos con valor 21 años, el mínimo del conjunto. Sin embargo, como se vio en el cruce con `organ`, la edad depende bastante del órgano: 21 años cae dentro del rango normal de pulmón y bazo, así que estos outliers globales no son errores ni casos raros, sino donantes jóvenes que resultan atípicos solo si se ignora a qué órgano pertenecen. No se eliminó ni transformó ninguna observación; se documenta el hallazgo.

En `img_height` el resultado es distinto. Como el 75 % de las imágenes miden exactamente 3000 px, el rango intercuartílico es cero y el método marca como outlier cualquier imagen que no mida 3000 (25 de 351, concentradas en riñón y próstata). Aquí el método clásico no resulta útil porque la variable no es continua en la práctica, sino casi binaria: 3000 o no 3000. La explicación más probable es que esas imágenes sean recortes de tejido que no alcanzaron el tamaño estándar de escaneo, no errores de carga, de modo que tampoco se descartan.

Sobre valores faltantes, `train.csv` no presenta ningún valor nulo en sus 351 filas, por lo que no fue necesaria ninguna decisión de imputación o eliminación.

4.7. Variable derivada: área de la FTU

Las variables tabulares originales dicen poco sobre el problema real. La información que de verdad importa está dentro de la columna `rle`, porque es la que describe lo que el modelo debe predecir. Por eso se construyó una variable derivada.

Aprovechando que el formato `rle` almacena pares (inicio, longitud), basta con sumar las longitudes para obtener la cantidad de píxeles marcados, sin necesidad de reconstruir la máscara completa. A partir de ahí se define:

$$\text{mask_frac} = \frac{\text{píxeles marcados como FTU}}{\text{img_height} \times \text{img_width}}$$

es decir, la proporción de la imagen ocupada por la unidad funcional de tejido.

Cuadro 5: Proporción de la imagen ocupada por la FTU, por órgano

Órgano	n	media	mediana	mín	máx
largeintestine	58	0.193	0.196	0.021	0.348
prostate	93	0.154	0.138	0.010	0.429
spleen	53	0.101	0.086	0.008	0.343
kidney	99	0.030	0.028	0.003	0.080
lung	48	0.021	0.013	0.001	0.089
global	351	0.099	0.059	0.001	0.429

4.8. Gráficos exploratorios

4.8.1. Gráficos univariados




Figura 1: Histogramas y diagramas de caja de edad, alto de imagen y proporción de FTU.

En `age` la distribución va de 21 a 84 años, se concentra entre los 55 y los 73 y tiene una mediana de 60 años. Es una población de donantes mayoritariamente adulta mayor, y la cola hacia los donantes jóvenes es bastante más delgada, de modo que el conjunto no representa por igual todas las edades.

En `img_height` el gráfico se ve casi como una sola barra: 326 de las 351 imágenes son de 3000×3000 píxeles y el resto son algo más pequeñas. El diagrama de caja marca todas esas imágenes menores como outliers, pero como ya se explicó no son errores.

En `mask_frac` la distribución está claramente sesgada a la derecha: la mediana es 0.059, alrededor del 6 % de la imagen, pero existen casos que llegan a 0.43. Esto significa que en la mayoría de las imágenes la estructura a segmentar ocupa una parte pequeña de la fotografía, lo cual implica un problema con clases fuertemente desbalanceadas a nivel de píxel.

4.8.2. Gráficos de barra de las variables categóricas




Figura 2: Frecuencia de órgano, sexo y fuente de datos.

Los tres gráficos de barra confirman visualmente lo descrito en las tablas de frecuencia. El caso de `data_source` es particularmente elocuente: una sola barra, porque las 351 filas pertenecen a HPA. La variabilidad entre laboratorios, que constituye la dificultad principal del reto, no se puede observar dentro de estos datos.

4.8.3. Cruces gráficos




Figura 3: Proporción de FTU por órgano, edad por órgano y composición por sexo dentro de cada órgano.

El primer panel es el más informativo. La proporción de imagen ocupada por la FTU cambia drásticamente según el órgano: en intestino grueso la mediana es de casi 0.20 y en próstata de 0.14, mientras que en pulmón apenas llega a 0.013 y en riñón a 0.028. Es decir, las FTU de pulmón ocupan alrededor de quince veces menos superficie que las de intestino grueso. La dispersión también difiere: próstata y bazo presentan cajas muy anchas y intestino grueso una más compacta. Encontrar la FTU no es el mismo problema en cada órgano.

El segundo panel muestra el caso de intestino grueso, con mediana de 83 años frente a los 57 a 59 de los otros cuatro órganos. El tercero muestra el caso extremo de próstata, 100 % masculino.

4.8.4. Gráficos de dispersión




Figura 4: Relación entre edad y proporción de FTU, y entre tamaño de imagen y proporción de FTU, coloreadas por órgano.

El primer gráfico de dispersión contiene el hallazgo más sutil del análisis. Si se calcula la correlación entre edad y proporción de FTU sobre las 351 filas en conjunto, resulta $r = 0,248$: una relación positiva débil pero visible, que invitaría a concluir que a mayor edad del donante mayor es el tamaño de la FTU.

Al separar por órgano, esa relación desaparece o se invierte:

Cuadro 6: Correlación entre edad y proporción de FTU, global y por órgano

Grupo	n	r (age, mask_frac)
Global	351	0,248
kidney	99	−0,178
largeintestine	58	0,139
lung	48	−0,396
prostate	93	0,003
spleen	53	0,028

Lo que ocurre es que la correlación global no mide una relación entre edad y tamaño de FTU, sino que captura el efecto del órgano. Intestino grueso tiene simultáneamente los donantes de mayor edad (mediana de 83 años) y las FTU más grandes (19.6 % de la imagen), de modo que al mezclar todos los órganos en una sola nube ese grupo arrastra la correlación hacia arriba. Se trata de un caso de paradoja de Simpson: la tendencia que aparece en el agregado se contradice al observar cada subgrupo por separado.

La conclusión práctica es doble. Primero, la edad no sirve para anticipar el tamaño de la FTU. Segundo, y más importante, cualquier correlación calculada sobre este conjunto sin estratificar por órgano debe mirarse con desconfianza.

El segundo gráfico confirma que los puntos se apilan casi todos sobre la línea de 3000 px, y que los pocos que quedan a la izquierda son las imágenes recortadas. La correlación entre tamaño de imagen

y proporción de FTU es $-0,079$, prácticamente nula, lo que indica que las imágenes más pequeñas no contienen FTU proporcionalmente más grandes ni más pequeñas. El recorte no introdujo un sesgo en la variable objetivo.

4.9. Exploración visual de las imágenes

Sobre una muestra reducida de `train_images` se decodificó la máscara completa mediante la función inversa del `rle` y se superpuso sobre el tejido. Todas las muestras son cortes teñidos con PAS, con tonos rosados y morados semejantes entre sí, y en todas hay zonas de fondo blanco donde no hay tejido.

La máscara superpuesta muestra que las FTU no forman una sola región compacta: en la mayoría de los órganos son varias regiones separadas dentro de la misma imagen, y su forma cambia por completo de un órgano a otro. El contraste entre la FTU y el tejido circundante tampoco es uniforme. En intestino grueso y próstata las estructuras se distinguen a simple vista, mientras que en pulmón y riñón la FTU se confunde mucho más con el tejido de alrededor y ocupa una fracción mínima de la fotografía, lo cual concuerda con lo observado en la distribución de `mask_frac`.

5. Hallazgos y conclusiones

5.1. Resumen de hallazgos

1. Variables sin información. `pixel_size` vale 0.4 en las 351 filas y `tissue_thickness` vale 4.0 en todas. Son constantes, su varianza es cero y por eso aparecen como NaN en la matriz de correlación. Además `img_height` e `img_width` son iguales entre sí en todas las filas y en el 93 % de los casos valen 3000. De las variables tabulares, las únicas con información real son `organ`, `sex`, `age` y la variable derivada de `rle`.

2. Desbalance en varios ejes simultáneos. Por órgano (99 riñones contra 48 pulmones), por sexo (229 hombres contra 122 mujeres, en buena parte por los 93 casos de próstata) y por edad, con una concentración fuerte entre los 55 y los 73 años. Además, órgano y edad no son independientes: intestino grueso tiene una mediana de 83 años frente a los 57 a 59 del resto.

3. Variable objetivo fuertemente desbalanceada. La FTU ocupa en mediana apenas el 5.9 % de la imagen, y esa proporción varía enormemente según el órgano: 19.6 % en intestino grueso contra 1.3 % en pulmón. Un modelo de segmentación entrenado sobre estos datos enfrenta un desbalance de clases severo a nivel de píxel, y ese desbalance no es uniforme entre órganos.

4. Correlación global espuria. La relación positiva entre edad y tamaño de FTU que aparece al analizar el conjunto completo se desvanece o se invierte al estratificar por órgano. Es un caso de paradoja de Simpson y obliga a analizar este conjunto siempre por subgrupos.

5. La generalización no es observable. Las 351 filas de `train.csv` tienen `data_source = HPA`. Las muestras de HuBMAP quedan del lado de los datos de prueba. Como la dificultad central del reto es que el modelo funcione con muestras preparadas en laboratorios distintos, resulta que la variabilidad que el modelo debe superar no se puede observar ni medir dentro de los datos de entrenamiento. Este es el hallazgo de mayor peso del análisis.

5.2. Conclusiones sobre los siguientes pasos

1. **Descartar las variables constantes.** `pixel_size` y `tissue_thickness` no aportan capacidad discriminativa y deben excluirse de cualquier modelo.
2. **Tratar el problema como segmentación desbalanceada.** Con una mediana de 5.9 % de píxeles positivos, un modelo que predijera fondo en toda la imagen alcanzaría más del 94 % de exactitud por píxel y sería completamente inútil. Corresponde emplear métricas como el coeficiente de Dice o la intersección sobre la unión, y funciones de pérdida pensadas para desbalance.
3. **Validar por órgano y no solo de forma global.** El desempeño promedio esconde que pulmón y riñón, con FTU quince veces más pequeñas, son casos sustancialmente más difíciles. Una validación estratificada por órgano es indispensable.
4. **Estratificar todo análisis estadístico por órgano.** La paradoja de Simpson encontrada demuestra que las correlaciones agregadas sobre este conjunto pueden llevar a conclusiones equivocadas.
5. **Apoyarse en aumentación de color y tinción.** Dado que el conjunto de entrenamiento no contiene variabilidad entre fuentes, la vía razonable para preparar al modelo frente a las muestras de HuBMAP del conjunto de prueba es simularla mediante aumentación de datos sobre color, saturación e intensidad de tinción, además de normalización de tinción.

Repositorio

El código, el cuaderno de análisis y las fuentes de este informe están versionados en:

<https://github.com/AleWWH1104/proyecto2-data>