Resultados y aplicación

Reto 18: Hackeando el cuerpo humano
HuBMAP: segmentación de unidades funcionales de tejido

Iris Ayala (23965) Jonatan Díaz (23837) Anggie Quezada (23643)

12 de octubre de 2026

Universidad del Valle de Guatemala
CC3084 Data Science, Semestre II, 2026

Problema, objetivo y resultado principal

Segmentación, no clasificación de órganos

Dada una imagen histológica, producir una máscara binaria de unidades funcionales de tejido (FTU): FTU frente a fondo. El órgano es metadato, no una clase predicha. Contexto: Jain et al. (2023) [1].

- Comparar tres arquitecturas con el mismo preprocesamiento y split.
- Medir solapamiento, diferencias por órgano y tiempo registrado.
- Integrar exploración, resultados e ingreso de imágenes en Streamlit.

SegFormer / MIT-B0 obtiene el mayor Dice medio registrado: 0.629. La predicción local con pesos reales sigue pendiente de recuperar checkpoints.

Datos y EDA que orientan la interpretación

351 imágenes etiquetadas

Riñón: 99; próstata: 93; intestino grueso: 58; bazo: 53; pulmón: 48. Anotaciones FTU en RLE.

EDA previo: fuente HPA, tamaño de píxel de referencia 0,4 μm; mediana global de cobertura FTU: 5.9 %. No confundir esta mediana con un porcentaje global de píxeles.

Implicaciones

- Desbalance de órganos y de FTU frente a fondo.
- Cobertura distinta según órgano: no basta el promedio global.
- Edad, sexo y órgano se relacionan; EDA no demuestra causalidad.

Fuente: EDA previo y `splits.csv`; `train.csv` no está disponible localmente.

Split reproducible y límites de fuga de información

Órgano	Entrenamiento	Validación	Prueba
Riñón	69	15	15
Próstata	65	14	14
Intestino grueso	40	9	9
Bazo	37	8	8
Pulmón	34	7	7
Total	245	53	53

- Estratificación por órgano, semilla 42; conservar `data/splits.csv`.
- Checkpoint elegido por Dice de validación; umbral fijo de 0.5.
- Prueba: solo resultados ya registrados; no ajustar ni reevaluar aquí.
- Split por imagen: no demuestra separación por donante o laboratorio.

Entrada compartida: de la histología al tensor

1. Conversión RGB uint8; referencia física de $0{,}4\,\mu$m/píxel.
2. Redimensionamiento a 384×384; máscaras con vecino más cercano.
3. Normalización ImageNet: media $(0{,}485, 0{,}456, 0{,}406)$ y desviación $(0{,}229, 0{,}224, 0{,}225)$.
4. Solo entrenamiento: volteos, rotación, escala y cambios de color, brillo, gamma y desenfoque. Validación/prueba: sin aumentación aleatoria.

Qué recibe el modelo

Píxeles de la imagen; edad, sexo, órgano y cobertura RLE son descriptivos. La máscara es el objetivo, nunca una entrada de inferencia.

Aumentación de tinción como motivación: Tellez et al. (2019) [5]. No se implementa una normalización de tinción dedicada.

Tres modelos: comparación controlada

U-Net / ResNet34 Línea base encoder–decoder con conexiones de salto: detalle local y contexto [2].

U-Net++ / ResNet34 Conexiones de salto rediseñadas para explotar características multiescala [3].

SegFormer / MIT-B0 Encoder transformer jerárquico y decoder ligero; alternativa compacta a las redes convolucionales [4].

Condiciones comunes

Encoder preentrenado; salida de un canal, logits binarios; misma resolución, split, pérdida y umbral. Es una comparación de estas ejecuciones, no de todo el potencial de cada familia.

Perfil conservador realmente utilizado

Memoria y optimización

- Resolución: 384×384.
- Batch físico: 1; acumulación: 2.
- Batch efectivo: 2; AMP en CUDA.
- AdamW, learning rate 10^{-4}.
- Weight decay 10^{-2}; Dice + BCE.

Selección y ejecución

- Hasta 20 épocas; paciencia: 5.
- Mejor checkpoint por Dice de validación.
- Semilla: 42; modelos secuenciales.
- Ejecución Windows registrada; RTX 4060 Laptop.

Fuentes: `experimentos_modelos.csv` y perfil del arnés Windows. No se modificó el perfil ni se ejecutó entrenamiento para esta entrega.

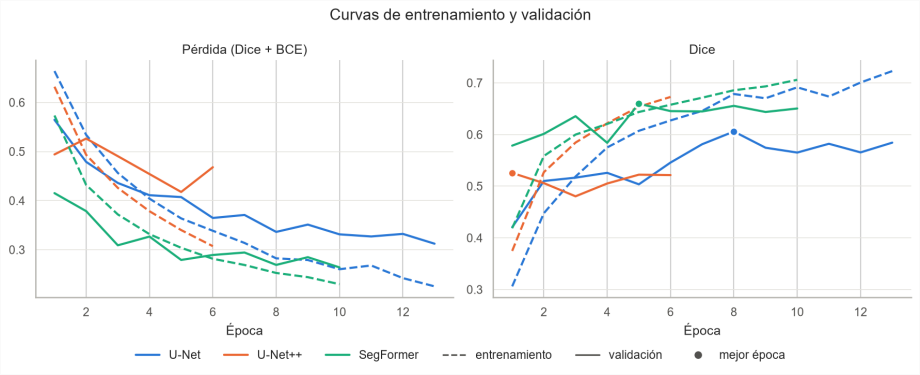
Historial: el mejor checkpoint no es la última época

Modelo	Épocas ejecutadas	Mejor época	Mejor val Dice
U-Net	13	8	0.6058
U-Net++	6	1	0.5256
SegFormer	10	5	**0.6596**

- Los tres registros indican detención temprana, no 20 épocas completas.
- U-Net++ termina con train Dice 0.6728 y val Dice 0.5214.
- Esa divergencia no prueba que el ruido causara la detención, ni fija un techo de rendimiento de U-Net++.

Fuentes: historial y experimentos existentes; no réplicas ni búsqueda adicional.

Curvas registradas de entrenamiento y validación



Línea punteada: entrenamiento; continua: validación; círculo: mejor época. El aumento en entrenamiento no garantiza mejora en validación.

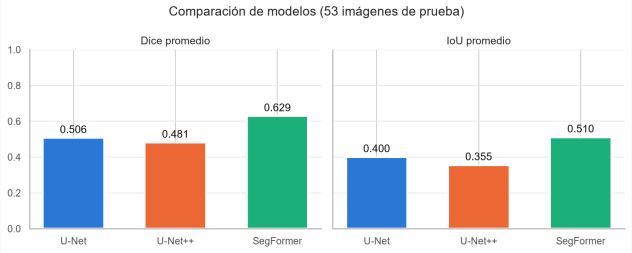
Cómo leer las métricas y el tiempo

$$\mathrm{Dice} = \frac{2|P \cap G|}{|P| + |G|}, \qquad \mathrm{IoU} = \frac{|P \cap G|}{|P \cup G|}$$

- P: máscara predicha; G: anotación. Rango $[0, 1]$, mayor es mejor.
- Sigmoid y umbral $\geq 0{,}5$; ambas máscaras vacías reciben 1.
- Media por imagen: 53 imágenes comunes, 159 filas para tres modelos. No es Dice calculado sobre todos los píxeles agregados.
- Tiempo del forward registrado en RTX 4060 Laptop, batch 1: excluye carga, preprocesamiento y presentación de resultados.

No es un benchmark del Mac ni una medida de latencia extremo a extremo.

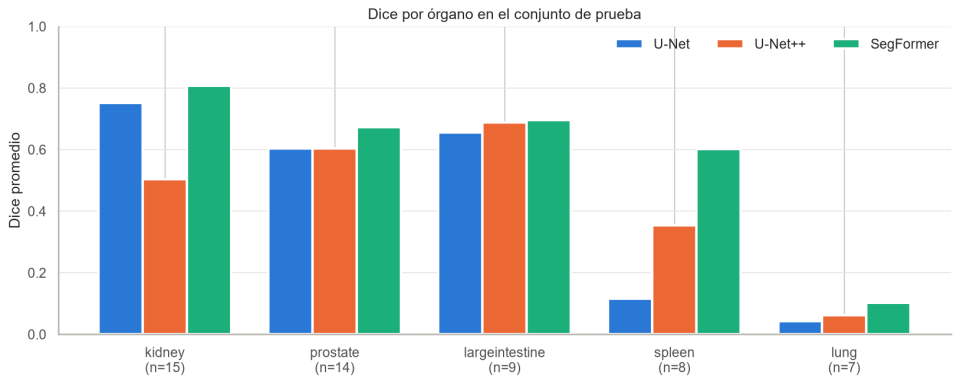
Resultados globales en las 53 imágenes de prueba



Modelo	Dice	IoU	Forward medio (ms)
U-Net	0.506	0.400	11.8
U-Net++	0.481	0.355	31.9
SegFormer	**0.629**	**0.510**	11.6

Fuente: medias de `data/metrics.csv`, sin nueva inferencia.

El órgano cambia la lectura del promedio



SegFormer tiene el mayor Dice medio en los cinco órganos del registro. Pulmón sigue siendo el grupo de menor solapamiento en los tres modelos.

Desglose: tamaños pequeños y diferencias descriptivas

Órgano	n	U-Net	U-Net++	SegFormer
Riñón	15	0.751	0.504	0.807
Próstata	14	0.603	0.604	0.673
Intestino grueso	9	0.656	0.687	0.696
Bazo	8	0.115	0.354	0.602
Pulmón	7	0.042	0.061	0.103

- Dice medio por órgano; los tamaños no son iguales.
- La cobertura FTU del EDA contextualiza el problema, pero no demuestra por qué falla un modelo.
- Sin intervalos de confianza o réplicas: no afirmar significancia.

Fuente: `metrics.csv`; no inspección ni selección nueva de imágenes de prueba.

Selección: SegFormer como opción de referencia

Evidencia de esta ejecución

Mayor mejor Dice de validación (0.6596), mayor Dice e IoU medios de prueba (0.629 y 0.510) y mayor Dice medio en cada órgano registrado.

- El checkpoint se eligió con validación, no con prueba.
- Mantener U-Net y U-Net++ como comparadores en la aplicación.
- Forward medio parecido a U-Net; no declarar superioridad de velocidad con una diferencia de solo 0.2 ms y sin estudio de variabilidad.
- La recomendación es local a este split y perfil; no valida desempeño clínico ni generalización a otros laboratorios.

Demostración honesta: cuatro páginas implementadas

Inicio Resumen registrado, modelo de referencia y alertas de activos faltantes.

Exploración Filtros y gráficos de metadatos; sin `train.csv`, solo información disponible en `splits.csv`.

Predicción Ingreso de imagen y selección de uno/todos los modelos disponibles; actualmente bloqueada por falta de checkpoints.

Rendimiento Dice/IoU, distribuciones, órganos, tiempos y curvas interactivas a partir de CSV, sin reevaluar imágenes.

Control lateral: Mostrar rendimiento

Oculta resumen, métricas, tablas y curvas en Inicio/Rendimiento; la preferencia persiste al navegar. No modifica los resultados guardados.

Nueva imagen: flujo disponible al recuperar los pesos

1. PNG/JPEG/TIFF de una sola imagen; máximo 64 MiB y 9 millones de píxeles.
2. Preprocesamiento compartido a 384 px; si falta espaciado, asumir explícitamente 0,4 μm/píxel, no inferirlo.
3. Inferencia CPU, uno o todos los modelos disponibles, secuencialmente.
4. Máscara binaria restaurada al tamaño original, superposición cian, porcentaje FTU y tiempo de forward CPU.

Estado local y alcance

Sin los tres archivos `.pt`, no hay nueva predicción real demostrada. Pruebas sintéticas no sustituyen aceptación con pesos reales. Sin máscara de referencia no se muestra Dice/IoU de la carga nueva.

Límites y pendientes de entrega

- Muestra pequeña: 53 imágenes de prueba, solo 7 de pulmón; una ejecución por modelo y sin incertidumbre cuantificada.
- Datos HPA y split por imagen: no validar transferencia de dominio a HuBMAP, independencia por donante ni uso clínico.
- Resolución 384: compromete detalle fino; no se estudiaron otras resoluciones.
- Faltan localmente `train.csv`, caché y checkpoints; recuperación y demostración con pesos reales pendientes.
- Informe final, capturas reales y enlace humano del Drive: entregables pendientes por confirmar, fuera de esta actualización.

Prototipo de investigación: no usar para diagnóstico ni decisiones médicas.

Conclusiones y acciones de entrega

1. **Comparación cumplida:** tres modelos, mismo split y perfil; SegFormer es la referencia con Dice 0.629 e IoU 0.510 registrados.
2. **El promedio no basta:** presentar siempre el desglose por órgano; el Dice 0.103 en pulmón limita el alcance del resultado.
3. **Aplicación funcional, aceptación real pendiente:** demostrar exploración y resultados ahora, sin simular una predicción.
4. **Antes de entregar:** recuperar activos autorizados, comprobar una carga nueva con pesos reales y completar informe/Drive.

Reproducción de la demo y checklist: `README.md`. Conservar métricas/splits; no reentrenar ni reevaluar para preparar la presentación.

Referencias: contexto y arquitecturas

- Jain, Y. et al. (2023). Segmenting functional tissue units across human organs using community-driven development of generalizable machine learning algorithms. *Nature Communications, 14*, 4656. doi:10.1038/s41467-023-40291-0.
- Ronneberger, O., Fischer, P. y Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. *MICCAI 2015*, 234–241. doi:10.1007/978-3-319-24574-4_28.
- Zhou, Z., Siddiquee, M. M. R., Tajbakhsh, N. y Liang, J. (2020). UNet++: Redesigning skip connections to exploit multiscale features in image segmentation. *IEEE Transactions on Medical Imaging, 39*(6), 1856–1867. doi:10.1109/TMI.2019.2959609.

Referencias: transformer y preprocesamiento

- Xie, E., Wang, W., Yu, Z., Anandkumar, A., Alvarez, J. M. y Luo, P. (2021). SegFormer: Simple and efficient design for semantic segmentation with transformers. *Advances in Neural Information Processing Systems, 34*, 12077–12090. Artículo en NeurIPS.
- Tellez, D. et al. (2019). Quantifying the effects of data augmentation and stain color normalization in convolutional neural networks for computational pathology. *Medical Image Analysis, 58*, 101544. doi:10.1016/j.media.2019.101544.

Fuentes reutilizadas de `informe/referencias.bib`. Esta presentación no acredita una auditoría de formato APA o de indexación.