

Análisis Exploratorio

Reto 18: Hackeando el cuerpo humano

HuBMAP: segmentación de unidades funcionales de tejido

Iris Ayala (23965) Jonatan Díaz (23837) Anggie Quezada (23643)

7 de septiembre de 2026

Universidad del Valle de Guatemala

CC3084 Data Science, Semestre II, 2026

Introducción

Contexto

- HuBMAP: mapear el cuerpo humano a nivel de célula
- FTU: grupo de células alrededor de un vaso sanguíneo con una función en el órgano
- Cinco órganos, cinco tipos de FTU distintos
- Tinción PAS → tono rosado/morado en las imágenes

Situación actual

- Hoy un patólogo marca las FTU a mano
- Lento, subjetivo, no escala
- Muestras del mismo órgano se ven distinto según el laboratorio

Problema científico y objetivos

Pregunta de investigación

A partir de una imagen de tejido, ¿se puede entrenar un modelo que marque con precisión dónde están las unidades funcionales de tejido, sin importar el órgano ni la fuente de la muestra?

Objetivo general. Explorar y describir los datos para entender cómo están compuestas las imágenes y las variables que las acompañan, como base para una futura solución de segmentación.

Objetivos específicos.

1. Describir las variables numéricas y categóricas y detectar diferencias entre grupos.
2. Analizar cómo se relacionan órgano, fuente, edad y sexo.
3. Cuantificar el área que ocupa la FTU y comparar su distribución entre órganos.

Los datos

Qué tenemos

train.csv

- 351 observaciones, una por imagen
- 10 variables
- 0 valores nulos
- 0 filas duplicadas

Limpieza aplicada: convertir organ, data_source y sex a tipo categórico. Nada más hizo falta.

Variable	Tipo
id	identificador
organ	categórica
data_source	categórica
sex	categórica
img_height/width	numérica
pixel_size	numérica
tissue_thickness	numérica
age	numérica
rle	texto (máscara)

La columna rle: dónde está la información real

La máscara de la FTU no viene como imagen, viene comprimida en **run-length encoding**: pares de (posición inicial, longitud).

Por qué importa

Guardar una máscara de 3000×3000 píxeles como matriz sería inviable dentro de una celda de texto. El rle la reduce a unos miles de caracteres.


De ahí construimos la variable que de verdad describe el problema:

$$\text{mask_frac} = \frac{\text{píxeles marcados como FTU}}{\text{img_height} \times \text{img_width}}$$

Basta con **sumar las longitudes**, sin reconstruir la máscara completa.


Análisis exploratorio

Variables univariadas




Edad de 21 a 84 años, mediana 60. Casi todas las imágenes son de 3000×3000 . La proporción 5/15 de FTU está **sesgada a la derecha**: mediana de apenas 0.059.

Variables categóricas



Desbalance por órgano (99 riñones contra 48 pulmones) y por sexo (229 hombres contra 122 mujeres). Y data_source tiene una sola barra. Volvemos a eso en un momento.

Cruces por órgano



Próstata es 100 % masculino, lo cual es biología y no un error. Intestino grueso tiene una edad mediana de 83 años contra 57 a 59 del resto: **órgano y edad no son independientes.**

Outliers: cuidado con aplicarlos a ciegas

age: 13 outliers

Todos con valor 21 años. Pero 21 cae dentro del rango normal de pulmón y bazo.

Son atípicos solo si se ignora el órgano.

img_height: 25 outliers

El 75 % de las imágenes mide exactamente 3000 px, así que el rango intercuartílico es **cero** y el método marca todo lo que no sea 3000.

La variable es casi binaria, no continua.

En ambos casos se documenta el hallazgo y **no se elimina nada**. Sobre valores faltantes: no hay ninguno en las 351 filas.

Hallazgos

Hallazgo 1: hay variables que no dicen nada

Constantes en las 351 filas

`pixel_size = 0,4`

`tissue_thickness = 4,0`

Varianza cero. Por eso aparecen como NaN en la matriz de correlación: el coeficiente de Pearson implica dividir entre la desviación estándar.

No es un bug del código.


Y además

`img_height = img_width` en todas las filas: las imágenes son cuadradas.

326 de 351 son de 3000×3000 .

De las variables tabulares, solo `organ`, `sex`, `age` y la derivada de `r1e` tienen información real.

Hallazgo 2: la FTU no ocupa lo mismo en cada órgano




Órgano	mediana
largeintestine	19.6 %
prostate	13.8 %
spleen	8.6 %
kidney	2.8 %
lung	1.3 %
global	5.9 %

Quince veces de diferencia entre intestino grueso y pulmón.

Encontrar la FTU no es el mismo problema en cada órgano.

Hallazgo 3: una correlación que engaña



Hallazgo 3: paradoja de Simpson

Grupo	r (edad, FTU)
Global	+0,248
kidney	−0,178
largeintestine	+0,139
lung	−0,396
prostate	+0,003
spleen	+0,028

La correlación global **no mide edad contra tamaño de FTU**. Mide el órgano disfrazado.

Intestino grueso tiene a la vez los donantes más viejos (mediana 83 años) y las FTU más grandes (19.6 %). Al mezclar todo, ese grupo arrastra la correlación hacia arriba.

Implicación

Cualquier correlación calculada sobre este conjunto **sin estratificar por órgano** es poco confiable.

Hallazgo 4: el desbalance está en varios ejes a la vez

Por órgano

99 riñones
contra
48 pulmones

Por sexo

229 hombres
contra
122 mujeres

Por edad

Concentrado
entre
55 y 73 años

Y no son independientes entre sí: los 93 casos de próstata son todos masculinos, e intestino grueso concentra a los donantes de mayor edad.

El desbalance de un eje se filtra en los otros.

Hallazgo 5: la dificultad del reto no está en los datos

Las 351 filas tienen `data_source = HPA`

No hay ni una sola observación de HuBMAP en `train.csv`.

Las muestras de HuBMAP quedan del lado del conjunto de prueba de la competencia.

Pero la dificultad central del reto es justamente que el modelo funcione con muestras preparadas en **laboratorios distintos**.

Conclusión

La variabilidad que el modelo tiene que superar **no se puede observar ni medir** dentro de los datos de entrenamiento.

Conclusiones

1. **Descartar las variables constantes.** `pixel_size` y `tissue_thickness` no discriminan nada.
2. **Tratar el problema como segmentación desbalanceada.** Con 5.9 % de píxeles positivos, predecir fondo en toda la imagen daría más del 94 % de exactitud por píxel y sería inútil. Usar Dice o IoU, no exactitud.
3. **Validar por órgano, no solo en global.** El promedio esconde que pulmón y riñón son mucho más difíciles.
4. **Estratificar todo análisis por órgano.** Lo demostró la paradoja de Simpson.
5. **Apoyarse en aumentación de color y tinción.** Es la única vía para simular la variabilidad entre fuentes que el entrenamiento no contiene.

Gracias

`github.com/AleWH1104/proyecto2-data`